



AULA 3

Aplicações de métodos não supervisionados



Objetivos de aprendizagem da aula

Ao final desta aula, você irá:

- Compreender os métodos não supervisionados para redução de dimensionalidade: PCA e MDS.
- Apresentar os métodos não supervisionados para clusterização: *k-means*, HCA e DBScan.

Que história é essa?

Nesta aula, vamos conhecer os métodos de aprendizado não supervisionado. Muitas vezes, o aprendizado não supervisionado é relacionado apenas aos métodos de clusterização (mais precisamente, ao *k-means*). Vamos ver que existem muitas outras aplicações nessa modalidade e conhecer um pouco mais sobre as questões que envolvem a dimensionalidade dos dados. A análise dimensional é importante para ajudar na performance de qualquer algoritmo de *machine learning* e etapa fundamental da análise do *dataset*. Entenderemos como isso funciona e como podemos usufruir de seus resultados durante a etapa de pré-processamento dos dados.


Aprendizado não supervisionado

O aprendizado não supervisionado é uma modalidade de *machine learning* em que os dados não têm o “gabarito” para o treinamento.

Sendo mais formal, as amostras do *dataset* não são rotuladas e não permitem relacionar os atributos à classe correta.




Dessa forma, **precisamos utilizar métodos que identifiquem padrões e estruturas nos dados recebidos** (que podem ser agrupamentos, anomalias, subespaços, etc.). Perceba que, muitas vezes, até poderíamos adicionar os rótulos nas amostras, mas isso pode ser difícil, por uma série de questões. Por exemplo, o ato de coletar e rotular um grande conjunto de exemplos pode custar muito tempo, esforço e investimento.



Assim, nosso principal interesse é desvendar a organização dos padrões existentes nos dados por meio da criação de *clusters* (agrupamentos) consistentes. Observe que amostras com características semelhantes tendem a participar do mesmo conjunto/classe.

Podemos, então, dizer que, quanto mais semelhantes, maior a probabilidade de receberem o mesmo rótulo. Então, podemos usar os métodos de agrupamento para identificar seus conjuntos com menos esforço e, só então, rotulá-los mais rapidamente.

Outra aplicação é utilizarmos essas técnicas em dados sobre os quais não temos nenhum conhecimento, para descobrirmos as características (similaridades e diferenças) entre os grupos encontrados e derivarmos conclusões úteis a seu respeito. Para decidirmos se as amostras são semelhantes, utilizamos medidas numéricas na comparação entre dois objetos. As medidas podem indicar a similaridade ou dissimilaridade.



Mantendo o foco

A similaridade mede a igualdade/semelhança entre dois objetos, ou seja, quanto mais parecidos, mais alta a similaridade. Já as medidas de dissimilaridade medem o quão diferentes são dois objetos. Dessa forma, quanto mais parecidos, menor a dissimilaridade.

Seu resultado é apresentado no intervalo entre 0 (não similar) e 1 (completamente similar). Seus resultados podem estar no intervalo [0,1] ou [0,∞], que é ainda mais útil e comum. As funções que não limitam o intervalo de dissimilaridade também são chamadas de funções de “distância” e consideradas um tipo especial de dissimilaridade.

► **Medidas de dissimilaridade:**

- Distância de Manhattan.
- Distância euclidiana.
- Distância de Mahalanobis.
- Distância de Hamming.

► **Medidas de similaridade:**

- Produto interno (*inner*).
- Medida de Tanimoto.



Saiba mais sobre as etapas do processo de aprendizagem não supervisionada.

Interativo

Descrição do interativo



Reflita

Diferentes escolhas de atributos, medidas de proximidade, critérios de agrupamento e algoritmos de agrupamento levam a resultados totalmente diferentes. Qual resultado é o correto?

Dimensionalidade


A análise de dimensionalidade é um dos aspectos mais importantes da análise exploratória e do pré-processamento de dados. Por meio dela, podemos minimizar as complexidades das amostras e permitir que os algoritmos de *machine learning* encontrem melhores resultados com menos esforço.



Mantendo o foco

Por exemplo, caso existam dois atributos que sejam derivados um do outro ou altamente correlacionados, um deles é redundante. O atributo irrelevante adiciona mais esforço ao algoritmo e ainda contribui por aumentar o ruído durante o treinamento. Nessa etapa, podemos realizar duas ações: a seleção de atributos ou a redução dimensional.

A **seleção é mais simples de compreender, basta selecionar os atributos**, criando um subconjunto que, de fato, representa as principais características das amostras. A **redução de dimensionalidade mantém a influência de todas as dimensões**, considerando o quanto cada uma delas contribui com a representação em dimensão inferior.




Para entendermos como funciona, imagine um cubo. São três dimensões: largura, altura e profundidade. Dependendo do ângulo que vemos, podemos perceber todas as dimensões ao olharmos apenas duas. Olhando de um ângulo específico, vemos apenas um quadrado que esconde a profundidade.

Agora, imagine que vamos bater uma foto desse cubo ou desenhá-lo em uma folha de papel. Estaremos realizando a redução dimensional de três para duas dimensões e precisaremos nos preocupar com o ângulo certo para não perdemos informação. Desenhar apenas um quadrado no papel é diferente de desenhar um cubo.

Vamos entender agora os métodos que nos auxiliam nessa etapa

Formalmente, a redução de dimensionalidade é o processo de redução do número de atributos, obtendo-se um conjunto de variáveis principais. O objetivo da redução de dimensão é resumir um espaço de dados tridimensional p original na forma de subespaço de componentes tridimensionais k inferiores, ou seja, apresentar 3D em duas dimensões.



Podemos usar essa análise como primeiro passo para visualização de dados, detecção de *outliers* e, principalmente, classificação, regressão ou agrupamento (*clustering*).

Por que reduzir a dimensionalidade dos dados?


Em modelos preditivos, muitos atributos podem confundir o classificador ou regressor e a redução funciona como uma etapa necessária ao processo de treinamento. Muitos atributos podem tornar a noção de distância entre pontos do espaço essencialmente inútil, e algoritmos baseados no cálculo de distâncias podem não funcionar. Em modelos exploratórios e preditivos, isso é a causa do problema da “maldição da dimensionalidade”.



“Maldição da dimensionalidade”

A “maldição da dimensionalidade” é um fenômeno que aparece quando temos uma grande quantidade de variáveis em um problema. Como mencionado anteriormente, há casos em que temos muitas variáveis altamente correlacionadas, ou seja, redundantes. Também podemos ter variáveis que não apresentam informações úteis ao problema. Isso faz com que o modelo selecionado tenha muitos parâmetros, podendo causar *overfitting*.

Por essas razões, precisamos utilizar técnicas para a reduzir a dimensionalidade dos dados.



Dimensionalidade dos dados

Neste vídeo você irá retomar sobre a dimensionalidade dos dados e conhecer mais alguns aspectos importantes através de exemplos.




Remoção de atributos

Remover atributos significa descartá-los. Normalmente, removemos atributos de um *dataset* quando há dois ou mais atributos dizendo praticamente a mesma coisa, ou quando a distribuição de dados está muito desbalanceada (poucos dados de um tipo e muitos de outro). No caso de atributos redundantes, vamos descartar aqueles que têm pequena variância em relação a atributos similares.

Você sabia que o código postal brasileiro é organizado de acordo com a posição de seu dígito? O CEP é um exemplo de dado que pode ser agrupado utilizando apenas os dois primeiros dígitos. Os dígitos restantes ajudam a otimizar o processo de entrega, sendo capazes de direcionar a correspondência mais rapidamente.

Observe na imagem a seguir como é organizado o CEP no Brasil.






Redução de atributos

O processo de redução busca resumir os dados que contêm muitas variáveis p , substituindo-os por um conjunto menor de k variáveis compostas, derivadas do conjunto original. Deve-se manter um bom equilíbrio entre a redução do tamanho, que cria uma representação mais compacta, e uma alta simplificação, que gera perda de informação relevante. Um dos algoritmos mais famosos para redução de atributos é a análise de componentes principais (PCA).

Análise de componentes principais (PCA)

A análise de componentes principais (PCA – principal *component analysis*) busca um meio de condensar a informação contida em várias variáveis originais em um conjunto menor de variáveis estatísticas (componentes), com perda mínima de informação.

O número de componentes principais define o novo número de atributos. Geralmente, os primeiros componentes são os mais importantes, já que explicam a maior parte da variação total. Seu uso é fundamental para acelerar o processo de aprendizado supervisionado. Os métodos de regressão e classificação podem ser aproximados, sem grandes perdas de performance.



O objetivo da PCA é **rotacionar** os eixos desse espaço p -dimensional para novas posições (**eixos principais**), com as seguintes propriedades:

- Os componentes são ordenados de modo que **o eixo principal 1 tem a maior variância**, o eixo 2 tem a próxima maior variância, ..., e o último eixo tem a menor variância.
- A covariância entre cada par de eixos é zero (**os eixos principais não são correlacionados**).

Se selecionados apenas os primeiros k componentes, estes definem um hiperplano k -dimensional que “melhor se ajusta” à nuvem de pontos formada pelos dados analisados. Do ponto de vista da variância total dos p atributos, os PCs 1 até k representam a proporção máxima possível de variância que pode ser mostrada em k dimensões.



Fique ligado

A medida de dissimilaridade usada na PCA é a distância euclidiana calculada a partir dos p atributos como uma medida de dissimilaridade entre os n objetos. A PCA calcula as k melhores

possíveis dimensões ($k < p$) a partir da distância euclidiana entre os objetos.



Utilize esse parâmetro para identificar a quantidade de componentes ideal para a redução dimensional.


Valores acima disso podem continuar complexos desnecessariamente, e valores abaixo desse patamar podem criar projeções com um número de dimensões menor que o ideal e, assim, perder explicabilidade.

Escalonamento multidimensional (MDS)

O escalonamento multidimensional (MDS – *multidimensional scaling*) representa as dissimilaridades como distâncias entre pontos em um espaço de baixa dimensão (normalmente, duas dimensões), de modo que as distâncias correspondam o mais próximo possível às dissimilaridades.

Apesar de ser um método diferente, pode ser considerado equivalente à PCA com dois componentes principais, quando usamos a distância euclidiana.

O MDS apresenta um resultado melhor que a PCA, quando utilizamos funções de similaridades não métricas.



Apesar de ser um método diferente, pode ser considerado equivalente à PCA com dois componentes principais, quando usamos a distância euclidiana.

O MDS apresenta um resultado melhor que a PCA, quando utilizamos funções de similaridades não métricas.

Durante a análise exploratória dos dados, é comum utilizarmos o MDS como método de análise e visualização para identificarmos características em comum entre os dados. Assim, **identificamos visualmente as dissimilaridades entre pares de objetos**. Também podemos usá-lo para representar uma matriz de proximidades (semelhança ou dissemelhança) entre uma série de tuplas de dados, de modo a facilitar sua visualização (em 2D ou 3D).

Agrupamento

O agrupamento é, muitas vezes, considerado sinônimo de aprendizado não supervisionado (principalmente o algoritmo *k-means*). **Seu principal objetivo é desvendar a organização dos padrões existentes nos dados por meio de *clusters* (agrupamentos) consistentes. Com isso, é possível descobrir similaridades e diferenças entre os padrões encontrados, assim como derivar conclusões úteis a respeito deles. O agrupamento (clusterização) é o processo que usamos para criar conjuntos de objetos e definir conjuntos (classes) de objetos similares.** Assim, podemos dizer que um *cluster* é uma coleção de objetos que são similares uns aos outros e dissimilares a objetos pertencentes a outros *clusters*.

Para que isso aconteça, é necessário definir um critério de similaridade que deverá ser usado durante o processo de criação de grupos. Podemos utilizar grandes quantidades de dados não rotulados para encontrar padrões existentes neles e, somente depois, supervisionar a rotulação dos agrupamentos encontrados. Essa abordagem é muito utilizada em aplicações de mineração de dados (*datamining*), quando o conteúdo de grandes bases de dados não é conhecido antecipadamente.



Existem três categorias principais de algoritmos de clusterização:

- Sequenciais (baseados em centroides).
- Hierárquicos.
- Baseados em densidade.

A seguir, vamos conhecer um exemplo de cada um deles.

K-MEANS

É a técnica mais simples de aprendizagem não supervisionada. Trata-se de um algoritmo sequencial que procura fixar *k* centroides (de maneira aleatória), um para cada grupo (*clusters*).

Cada centroide é o ponto que define o centro do grupo, podendo ser associado a uma amostra real ou calculado a partir da média das amostras que pertencem ao grupo em questão. O algoritmo *k-means* procura associar cada indivíduo ao seu centroide mais próximo e, ao final do processo, deve recalcular os centroides com base nos indivíduos classificados.


O algoritmo do *k-means* é bem simples e segue o exemplo abaixo:

- (1) Selecione **k** centroides iniciais.
- (2) Forme **k clusters**, associando cada exemplo ao seu centroide mais próximo.
- (3) Recalcule a posição dos centroides com base no centro de gravidade do *cluster*.
- (4) Repita os passos 2 e 3 até que os centroides não sejam mais movimentados.

Vamos supor o exemplo, clicando na flecha ao lado:

Interativo

Descrição do interativo



Conhecendo o *K-MEANS*



Neste vídeo você verá uma explicação sobre o algoritmo sequencial *K-MEANS*, revisando o exemplo apresentado com mais detalhes.



Clusterização hierárquica

A clusterização hierárquica produz uma árvore que demonstra as distâncias entre os grupos e subgrupos dentro do mesmo *cluster*. Também é chamada de HCA (*hierarchical cluster analysis*), sendo muito útil para encontrar pequenas diferenças entre os elementos de um mesmo grupo. Existem duas classes de algoritmos: aglomerativo e divisivo.

O algoritmo aglomerativo define inicialmente que cada amostra é um *cluster* e vai produzindo uma sequência de agrupamentos com um número decrescente de *clusters* a cada passo. Os agrupamentos produzidos em cada passo resultam da fusão de dois *clusters* em um.

Formalmente, o agrupamento inicial $\mathfrak{R}_0$ consiste em N *clusters*, cada um contendo um único elemento de X . No primeiro passo, o agrupamento $\mathfrak{R}_1$ é produzido e contém $N-1$ conjuntos, tal que $\mathfrak{R}_0 \subset \mathfrak{R}_1$. Esse procedimento continua até o agrupamento final, $\mathfrak{R}_{N-1}$, ser obtido, o qual contém um único conjunto, isto é, o conjunto de dados X . Assim, a hierarquia dos agrupamentos resultantes é: $\mathfrak{R}_0 \subset \mathfrak{R}_1 \subset \mathfrak{R}_2 \subset \dots \subset \mathfrak{R}_{N-1}$.

- 1. Initialization:
 - 1.1. Choose $\mathfrak{R}_0 = \{C_i = \{x_i\}, i = 1, \dots, N\}$ as the initial clustering.
 - 1.2 $t = 0$.
- 2. Repeat
 - 2.1. $t = t + 1$
 - 2.2 Among all possible pairs of clusters (C_r, C_s) in $\mathfrak{R}_{t-1}$ find the one, say (C_i, C_j) , such that
$$g(C_i, C_j) = \begin{cases} \min_{r,s} g(C_r, C_s), & \text{if } g \text{ is a dissimilarity function} \\ \max_{r,s} g(C_r, C_s), & \text{if } g \text{ is a dissimilarity function} \end{cases}$$
 - 2.3 Define $C_q = C_i \cup C_j$ and produce the new clustering $\mathfrak{R}_t = (\mathfrak{R}_{t-1} - \{C_i, C_j\}) \cup \{C_q\}$.
- Until all vectors lie in a single cluster.



Já o algoritmo divisivo é o oposto, pois se inicia de um único grupo, que vai, sequencialmente, sendo dividido a cada passo. Ou seja, os agrupamentos produzidos em cada passo resultam da partição de um único *cluster* em dois.


Nesse caso, o agrupamento inicial $\mathfrak{R}_0$, para o algoritmo divisivo, consiste em um único conjunto X . No primeiro passo, o agrupamento $\mathfrak{R}_1$ é produzido e consiste em dois conjuntos, de modo que $\mathfrak{R}_1 \subset \mathfrak{R}_2$. Esse procedimento continua até que o agrupamento final, $\mathfrak{R}_{N-1}$, seja obtido, o qual contém N conjuntos, cada um consistindo em um único elemento de X . A hierarquia dos agrupamentos resultantes é: $\mathfrak{R}_0 \subset \mathfrak{R}_1 \subset \mathfrak{R}_2 \subset \dots \subset \mathfrak{R}_{N-1}$.

Generalized divisive scheme (GDS)



- 1. Initialization:
 - 1.1. Choose $\mathfrak{R}_0 = \{X\}$ as the initial clustering.
 - 1.2 $t = 0$.
- 2. Repeat
 - 2.1. $t = t + 1$
 - 2.2 For $i = 1$ to t
 - * 2.2.1 Among all possible pairs of clusters (C_r, C_s) that form a partition of $(C_{t-1,i}^1, C_{t-1,i}^2)$ that gives the maximum value for g .
 - Next i
 - 2.3 From the t pairs defined in the previous step choose the one that maximizes g . Suppose that this is $(C_{t-1,j}^1, C_{t-1,j}^2)$
 - 2.4 The new clustering is $\mathfrak{R}_t = (\mathfrak{R}_{t-1} - \{C_{t-1,j}\}) \cup \{C_{t-1,j}^1, C_{t-1,j}^2\}$
 - 2.5 For $i = 1$ to t
- Until all vectors lie in a single cluster.

Enfim, os métodos de clusterização sequenciais consideram todas as $2^{N-1}-1$ possíveis partições de X em dois conjuntos e selecionam o ótimo de acordo com um critério pré-especificado. Já o HCA é aplicado iterativamente a cada um dos dois conjuntos produzidos no estágio precedente, e o agrupamento final consiste em N clusters, cada um contendo um único vetor de X .



Clusterização hierárquica

Neste vídeo você irá conhecer mais detalhadamente esse método utilizado para agrupamento chamado clusterização hierárquica.



Métodos baseados em densidade

Diferentemente dos métodos anteriores, os algoritmos baseados em densidade identificam regiões densas que permitem a formação de clusters com diferentes formatos. São métodos muito resistentes à presença de ruídos e baseados no conceito de ε -vizinhança. Seja um espaço bidimensional, a ε -vizinhança de um ponto p é o conjunto de pontos contidos em um círculo de raio ε , centrado em p . Um dos algoritmos mais conhecidos que segue essa filosofia é o DBSCAN.

Density-based spatial clustering of applications with noise (DBSCAN)

O DBSCAN é um algoritmo que utiliza a densidade para agrupar pontos com valores similares. Ele procura identificar vizinhanças densas em que a maioria dos pontos está contida para definir se as amostras farão parte de um cluster ou se seriam anomalias (outliers). O algoritmo recebe os seguintes parâmetros: ε (raio da vizinhança) e MinPts (número mínimo de pontos na vizinhança para definir um cluster).

Dessa forma, cada ponto pode ser classificado em uma das três categorias (clique nos títulos a seguir):




Interativo

Descrição do interativo

O DBSCAN segue o seguinte algoritmo:

Selecione um ponto aleatoriamente que não tenha sido atribuído a nenhum *cluster* e que não seja um *outlier*:

1. Calcule sua ϵ -vizinhança e determine se ele é um *core point*.
 - Se sim, comece um *cluster* ao redor desse ponto.
 - Se não, rotule como *outlier*.
2. Depois de ter encontrado o *core point*, expanda-o adicionando todos os pontos alcançáveis.
3. Repita os dois passos acima, até que todos os pontos sejam atribuídos a um *cluster* ou rotulados como *outliers*.



DBSCAN

Neste vídeo você irá conhecer um pouco mais sobre o método DBSCAN, muito utilizado para indexação de anomalia dos padrões.



Como vimos nesta aula, o **aprendizado não supervisionado** não trata apenas de algoritmos de agrupamento. Caso desejemos aplicar um algoritmo de clusterização (agrupamento) para extrair informação relevante de dados **não rotulados**, devemos decidir entre os **vários** algoritmos de agrupamento de dados.



Analise

Diferentes escolhas de atributos, medidas de proximidade, critérios de agrupamento e algoritmos de clusterização levam a resultados

totalmente diferentes. Você consegue mencionar quais são eles e em que momentos devemos decidir por um ou por outro?

Lembre-se de que os algoritmos de agrupamento podem ser usados para:

- descobrir *clusters* com forma arbitrária;
- identificar *clusters* de tamanhos variados;
- trabalhar com objetos com qualquer número de atributos (dimensões);
- exigir o mínimo de conhecimento para determinar os parâmetros de entrada;
- encontrar o número adequado de *clusters*;
- serem escaláveis, para lidarem com qualquer quantidade de objetos.



React de Mercado

Para finalizar a disciplina, convidamos o professor e pesquisador Héliο Lopes para este vídeo, onde ele vai nos trazer um pouco de sua experiência profissional.



Referências

Clique aqui para acessar as referências e créditos desta aula.



BISHOP, C. M. **Pattern recognition and machine learning**. New York: Springer, 2006.

BONACCORSO, G. **Machine learning algorithms**. 2. ed. Birmingham: Packt Publishing, 2018.

BRUCE, P.; BRUCE, A. **Practical statistics for data scientists**. Sebastopol: O'Reilly Media, California-USA. 2017.

DUDA, R.; HART, P.; STORK, D. **Pattern classification**. New York: John Wiley & Sons, 2000.

HAYKIN, S. S. **Neural networks**: a comprehensive foundation. Prentice Hall, 1999.

MITCHELL, T. **Machine learning**. McGraw-Hill Science/Engineering/Math, 1997.

Banco de imagens Pexels, Pixabay, Envato, Freepik e Shutterstock.