



AULA 1

Modelagem, projeto e
implementação de *data
warehouses*

A PROFESSORA

Fernanda Baião

Professora do quadro principal do Departamento de Engenharia Industrial da PUC-Rio, onde orienta pesquisas de mestrado, doutorado e pós-doutorado e coordena projetos de pesquisa e desenvolvimento junto a empresas nas áreas de ciência de dados e modelagem conceitual. É doutora e mestre em engenharia de sistemas e computação pela COPPE/UFRJ, e seus tópicos de especialidade incluem ciência de dados, modelagem conceitual e ontologias, gestão de processos de negócio, economia comportamental e integração de dados em ambientes distribuídos através do alinhamento de ontologias. Liderou projetos de PD&I nas áreas de ciência de dados, BPM, arquitetura empresarial, gestão de dados e segurança da informação e engenharia de dados, em domínios de exploração e produção de óleo e gás, seguros, gestão de serviços de TI, predição de fraudes, *healthcare* e gestão de saúde pública.

O PROFESSOR

Sergio Lifschitz

Professor do quadro principal do Departamento de Informática da PUC-Rio, onde orienta pesquisas de mestrado, doutorado e pós-doutorado e coordena projetos de pesquisa e desenvolvimento junto a empresas nas áreas de banco de dados e ciência de dados. Seus tópicos de especialidade incluem banco de dados, ciência de dados, engenharia de dados e bioinformática, com desenvolvimento de ferramentas e sistemas em parceria com Fiocruz, UNB, UFRRJ, UFRJ e Inca. É doutor em informática, com especialização em bancos de dados e redes pela École Nationale Supérieure Des Télécommunications (ENST/Télécom Paris – França).

O CONVIDADO

Antony Seabra de Medeiros



Objetivos de aprendizagem da aula

Ao final desta aula, você irá:

- Definir um ambiente de inteligência do negócio (*business intelligence*) e seus componentes, em particular o papel de *data warehouses* (DW), *data marts* e *data lakes*.
- Descrever o potencial dos DW para tomadas de decisão nas organizações.
- Contrastar os ambientes transacional e analítico de sistemas nas organizações, suas fronteiras e convergência.
- Descrever diferentes abordagens de projeto e desenvolvimento de DW e *data marts*.
- Reconhecer características de um DW.
- Construir esquemas estrela para DW utilizando a modelagem dimensional, com o propósito de acompanhar indicadores de desempenho do negócio.
- Reconhecer operadores analíticos aplicáveis sobre um DW em diferentes gerações das arquiteturas de ambientes de inteligência de negócio (BI n.0)

Que história é essa?

O objetivo desta disciplina é introduzir e discutir os principais conceitos dos ambientes de inteligência de negócio (*business intelligence – BI*), em particular o papel central desempenhado por DW e *data lakes* no suporte à tomada de decisões e o processo de extração, transformação e carga para aquisição e integração dos dados organizacionais.

Ao longo das aulas, você aplicará diversos conceitos aprendidos em ambientes práticos de modelagem e consulta de dados estruturados e não estruturados, através de sistemas de gestão de dados relacionais e NoSQL, que adotam diversos modelos de processamento computacional e paradigmas de computação distribuída, voltados para cenários *big data*.

Além disso, nesta disciplina, você terá acesso a conteúdos sobre estes temas e materiais adicionais para que você tenha uma compreensão mais abrangente de temas avançados e aplicação prática em ambientes modernos de gestão de dados.

Nesta primeira aula, teremos o primeiro contato com o conceito de inteligência e análise de negócio (*business intelligence & analytics*), explicitando o papel central de repositórios de dados (DW, *data marts*, *data lakes*) como base histórica do conhecimento organizacional. Contextualizaremos o cenário atual *big data* e conheceremos desafios, técnicas e ferramentas utilizadas para aprimorar a gestão

do negócio orientada a dados. Serão analisadas as características essenciais de um DW, as diferentes abordagens para seu desenvolvimento e os diversos tipos de esquema disponíveis, com suas vantagens e desvantagens, com a modelagem na prática de um esquema de DW. Por fim, você conhecerá as principais diferenças entre os ambientes transacional e analítico nas organizações, suas fronteiras e potencial de convergência e como os operadores clássicos de um ambiente analítico podem auxiliar a tomada de decisões na prática em ferramentas *on-line analytical processing* (OLAP).

Big Data, Gestão de Desempenho Organizacional, Business Intelligence, Data Analytics & Data Science... Afinal, como tudo isso se relaciona?

Observe o diálogo fictício a seguir clicando nos *slides*.

Interativo

Descrição do interativo

Esse diálogo (fictício, inspirado em uma situação real em uma organização) ilustra mais uma decisão entre as diversas diariamente tomadas por todos os gestores e executivos de negócio em cada vez mais organizações ao redor do mundo. O que vimos experimentando no mundo todo é a utilização cada vez mais intensa de dados coletados historicamente, dentro e fora da organização, como base para controlar, analisar, avaliar, planejar, descobrir padrões e nos antecipar aos acontecimentos do mundo real e, dessa forma, suportar de forma mais racional uma decisão do negócio.


Com base nisso, veja a declaração de Pascale Hutz, *chief data officer* (CDO) da American Express, em um episódio do *The Data Chief*:

“Temos toda essa riqueza de informações... Você poderia pensar nisso quase como um fardo, mas realmente não é, é um ativo incrível. A mágica por trás disso é [a experiência do cliente está em] “costurar” todos os dados juntos, “peneirar” todos [esses dados], buscando o comportamento do cliente e onde ele esteve. E naquele momento em que você estiver entrando em contato, ser capaz de sintetizar todos esses eventos para prever por que você está ligando e estar pronto com informações para resolver seus problemas.”

Tradução nossa da declaração de Pascale Hutz, CDO da American Express, em um episódio do *The Data Chief*.

Fonte: <https://www.thoughtspot.com/data-trends/business-intelligence/business-intelligence-examples>

Na prática, no entanto, tal suporte é extremamente complexo, uma vez que o volume, a variedade e a velocidade de disponibilização dos dados (os três Vs característicos de cenários *big data*) crescem a cada instante.



A denominada era ***big data***, realidade nos dias atuais, tornou-se possível por um intenso desenvolvimento tecnológico, em que o aumento do poder computacional acompanhou a redução dos custos de dispositivos de armazenamento, permitindo que um volume de dados sem precedentes seja disponibilizado para processamento. Eles podem ser provenientes de diversas fontes, não apenas de bases de dados corporativas, mas também de páginas *web* e documentos XML, documentos textuais (em formato PDF ou de editores de texto proprietários), planilhas *stand-alone* (em formato CSV ou de editores de planilhas proprietários), registros (logs) de ações executadas através de sistemas de informação (ERP, WfMS, BPMS ou sistemas de propósito definido) ou mesmo de *posts* e comentários em redes sociais.

O desafio passou a ser, por um lado, construir ferramentas e algoritmos que – sob um novo paradigma de processamento de dados – sejam capazes de lidar simultaneamente com os três Vs durante a análise dos dados e, por outro lado, continuamente identificar perguntas relevantes sobre o negócio, cujas respostas direcionem o *pipeline* de dados (coleta, integração, armazenamento, cruzamento, processamento) para subsidiar os gestores em suas análises e tomadas de decisão. Tais desafios são os pilares para uma estratégia de gestão de desempenho organizacional.

A **gestão de desempenho organizacional** é o conjunto de processos gerenciais e analíticos, suportados por tecnologia, que permitem ao negócio definir objetivos estratégicos e então medir e monitorar o desempenho da organização em relação a tais objetivos, através de indicadores de desempenho. O escopo da gestão organizacional pode contemplar toda a organização, uma área funcional (departamento) ou mesmo um processo de negócio (conjunto de ações inter-relacionadas ou interativas que agrega valor a pelo menos um cliente).

Os processos analíticos da gestão de desempenho organizacional, quando direcionados por dados (***data analytics***), podem se dar em diversos níveis, a partir de um repositório de dados historicamente coletados sobre o negócio. Clique nos *cards* para conhecê-las melhor.

Interativo

Descrição do interativo

O ambiente tecnológico no qual a gestão de desempenho organizacional e seus processos analíticos são executados é denominado “ambiente de **inteligência de negócio**” (***business intelligence***). Nesses ambientes, a análise de dados nos níveis descritivo e diagnóstico é tradicionalmente suportada, envolvendo componentes como: (i) ferramentas de apoio ao processo de extração, transformação e carga de dados a partir das fontes operacionais (ETL); (ii) o repositório integrado de dados históricos (DW, *data marts* e *data lakes*, que serão definidos mais adiante); e (iii) ferramentas de apoio ao processamento analítico *on-line* (OLAP).

Já as análises de dados nos níveis preditivo e prescritivo – típicas de projetos de ciência de dados (*data science*) – são mais complexas, requerendo componentes mais avançados do ambiente de BI, como ferramentas de aprendizado de máquina (*machine learning*), que têm por objetivo a descoberta de padrões a partir dos dados mantidos no ambiente de BI.

Como veremos mais adiante, todos esses níveis de análise vêm sendo suportados pelos ambientes de BI modernos, que vêm se tornando verdadeiros ecossistemas, incorporando todas essas ferramentas de forma integrada, servindo como ambiente ideal de execução de projetos de *data analytics* e *data science* nas organizações.

Pode-se afirmar que iniciativas de ciência de dados, em qualquer organização, são idealmente suportadas por ambientes de inteligência de negócio.

A “inteligência do negócio” reside nos dados.

O ponto crítico de todo ambiente de inteligência de negócio é a construção de um repositório integrado de dados. Integração de dados é o processo de combiná-los de várias fontes, de forma a disponibilizar aos usuários uma visão unificada e logicamente consistente deles. Mas cuidado: integração e centralização são dois conceitos distintos, e, portanto, um repositório integrado não precisa necessariamente ser centralizado; na verdade, é cada vez mais frequente que organizações atuais hospedem seus grande repositórios integrados de dados em dispositivos de armazenamento que se encontram fisicamente distribuídos geograficamente, como é o caso dos ambientes em nuvem, atualmente utilizados por grande parte das organizações.

Para saber mais... além de favorecer a localidade dos dados (ou seja, permitir que o subconjunto de dados mais frequentemente acessados por uma instância de um sistema ou ferramenta computacional seja fisicamente hospedado em um dispositivo de armazenamento mais próximo – ou de acesso mais rápido – a ele), a distribuição de dados também favorece a utilização de processamento paralelo no acesso aos dados.

Os objetivos da integração de dados são:

- (a) facilitar o acesso e o reúso dos dados;
- (b) promover maior agilidade no acesso aos dados;
- (c) proporcionar maior flexibilidade, em caso de alterações no esquema da fonte de dados, por exemplo;
- (d) definir e compartilhar uma única versão da verdade sobre os dados (principalmente nos casos em que múltiplas cópias de um mesmo dado coexistem em diferentes fontes).


Apesar de crítica e de reconhecida importância, a integração de dados é um processo extremamente complexo e que pode ocupar grande parte do tempo despendido na gestão dos dados em uma organização.


O processo de integração de dados é complexo devido aos seguintes fatores:

- (i) por endereçar diversos problemas relacionados à qualidade dos dados a serem integrados (ausência de valores, inconsistência entre cópias, diferenças de representação, múltiplas versões da verdade, entre outros);
- (ii) por ser um esforço contínuo, uma vez que um grande volume de novos dados é constantemente disponibilizado, uma característica da era *big data*, como já vimos;
- (iii) por contemplar tanto fontes de dados intra-organizacionais (grandes tabelas em bases de dados corporativas, dados provenientes de sistemas legados que ainda estejam em funcionamento, planilhas e documentos relevantes para o negócio armazenados em pastas) quanto fontes de dados externas (índices e indicadores econômicos e monetários, como taxas de conversão entre moedas, índices financeiros, como cotações na bolsa de valores, dados meteorológicos, boletins epidemiológicos ou outros indicadores de outros domínios relevantes para o negócio, reportagens em fontes jornalísticas, *posts* e comentários em redes sociais, *streaming* de dados provenientes de sensores).

De fato, uma pesquisa da Forrester revela que as equipes de gestão de dados gastam 70% do seu tempo preparando e direcionando dados externos no processo de integração. Assim, a construção do repositório integrado de dados passa, portanto, por uma estratégia de integração de dados.

Uma das estratégias de integração de dados mais comumente utilizada para ambientes de BI é o armazenamento comum de dados (*common data storage*), no qual há a construção de um repositório com dados compartilhados.





Os 7 níveis de integração possíveis

Observe, no vídeo a seguir, outras estratégias de integração definidas na literatura.



Nos casos em que esse repositório armazena dados segundo um modelo estruturado (por exemplo, tabelas em um SGBD relacional, ou vetores em um SGBD multidimensional), tal repositório é denominado *data warehouse* (ou *data marts*, que, na verdade, representam subconjuntos do DW, desenvolvidos para propósitos mais específicos, como, por exemplo, para servir análises de apenas um processo do negócio). Já nos casos em que tal repositório armazena dados de forma não estruturada (isto é, em que os dados integrados são mantidos na mesma estrutura das fontes de dados originais – sejam eles grafos, tabelas, documentos, textos), tal repositório integrado é denominado *data lake*.

O pensamento operacional *versus* analítico

Como vimos, diversas organizações vêm adotando com sucesso estratégias de gestão de desempenho baseadas em dados, de forma a extrair valor da grande quantidade de dados tornada disponível pela onda crescente de iniciativas de transformação digital e cenário *big data* atual. Nesse contexto, as tomadas de decisão vêm sendo cada vez mais suportadas por ambientes de inteligência do negócio. Tal suporte, na prática, requer que fatos relevantes sejam historicamente coletados e adequadamente sintetizados, de forma a produzir e disponibilizar informação útil para os gestores do negócio. Tais gestores, então, devem analisar essas informações e tomar ações apropriadas com base nelas, considerando níveis de risco e de incerteza assumidos.



De olho no mercado

Em uma empresa de varejo, por exemplo, exemplos clássicos desse tipo de análise seriam responder as perguntas a seguir:

- Qual é o volume médio de vendas, em reais, dos nossos representantes em cada região geográfica?
- Para cada produto do nosso portfólio, qual é o total de vendas no último ano?
- Como tem variado o índice de participação de cada produto em nossas vendas (*product share*) ao longo dos três últimos anos?
- Existe alguma relação entre o desempenho dos representantes e sua faixa salarial?



Essa sequência de perguntas é o que tipicamente caracteriza o processamento analítico dos seres humanos, em oposição ao processamento transacional. O processamento analítico suporta as atividades de concepção da organização, e faz parte do desenvolvimento cognitivo (que, por sua vez, é a forma como os indivíduos adquirem conhecimento).

Já o pensamento transacional suporta as funções associadas à execução do negócio e está ligado à perspectiva operacional do negócio. Sistemas de informação que tipicamente suportam a perspectiva analítica são os *decision support systems* (DSSs), ou sistemas de suporte à decisão, enquanto folhas de pagamento e de vendas são sistemas na perspectiva operacional/transacional.

Essa distinção dá origem a dois tipos de processamento bem conhecidos na literatura, que nos auxiliam a entender as principais diferenças entre os ambientes computacionais nas organizações, suas fronteiras e complementaridades: processamento OLTP *versus* processamento OLAP.

O *on-line transactional processing* (OLTP) é típico da perspectiva operacional de uma organização. Como o próprio nome indica, ele é baseado em transações e prioriza questões relacionadas à velocidade e à automação de funções repetitivas (por exemplo, a venda de um produto, a alocação de uma tarefa a um recurso, o *check-in* de um hóspede, o cadastro de um cliente). Esse tipo de processamento preocupa-se majoritariamente com a situação corrente dos dados e em um nível de detalhe muito grande (quais produtos estão em estoque, quais pedidos estão em aberto, quais tarefas estão pendentes). Os sistemas que suportam o processamento OLTP tipicamente executam um grande número de consultas e de atualizações entrelaçadas.

Já o OLAP é típico da perspectiva analítica (ou informacional) de uma organização. Ele prioriza questões relacionadas à consistência e à veracidade dos dados e suporte à flexibilidade (possibilidade de ver

um mesmo dado sob múltiplas perspectivas: qual é o total de itens vendidos por ano? E por loja? E por produto?). Pode-se afirmar que o número de usuários de um sistema OLAP é bem menor que o de OLTP (afinal, são para apoio a atividades gerenciais), e esses usuários tipicamente requerem um número bem menor de consultas “pré-definidas”; por sua vez, é frequente que as consultas variem muito em tempo de execução, por refletirem o processamento analítico (inerentemente dinâmico e personalizado) de cada gestor.



Fique ligado

Para o processamento analítico, os dados históricos são muito relevantes, e espera-se que o número de consultas supere muito o número (ou, ainda, a frequência) de inserções (é ainda comum que as organizações reservem “janelas” de tempo periódicas para que novos dados sejam inseridos no repositório integrado e, assim, não impactem o desempenho das consultas gerenciais). Importante ressaltar que os dados “antigos” não são sobrepostos a cada nova atualização do repositório; em vez disso, criam-se versões dos dados, de forma a manter o histórico dos dados passados (por exemplo, um mesmo cliente pode estar relacionado a vários endereços, refletindo todos os locais em que residiu desde o seu primeiro cadastro no repositório da organização. Isso permite que mudanças no comportamento de compras – alteração de lojas de preferência, naturezas de produtos comprados – sejam rastreadas e possivelmente explicadas pelas diversas versões de um mesmo cliente ao longo do tempo).

Os sistemas que suportam o processamento OLAP têm seu desempenho muito influenciado pela necessidade de processamento de operações bem mais custosas computacionalmente, como é o caso das agregações e cruzamentos (por exemplo, calcule a média de venda, por vendedor e para cada produto, considerando apenas as vendas para clientes que já compraram anteriormente na mesma loja).

A tabela a seguir resume as principais diferenças entre os ambientes operacional (que tipicamente devem suportar processamento OLTP) e informacional (de suporte ao processamento OLAP). Analise-a:

Características	Ambientes operacionais (transacionais)	Ambientes informacionais (analíticos)
Conteúdo	Valores correntes, detalhados	Valores históricos, sumarizados segundo nível de granularidade pré-definido
Usuários	Disponível para muitos usuários, controle razoável sobre as plataformas	Disponível para poucos usuários e múltiplas plataformas
Atualizações	Dados dinâmicos, atualizações mais frequentes	Atualizações controladas, mantendo versionamento dos dados
Estrutura de dados	Relacional, própria para processamento transacional (caminhos longos de navegação)	Dimensional, própria para processamento analítico (caminhos curtos de navegação)
Uso	Estruturado, repetitivo, requisitos conhecidos	Desestruturado, consulta sob diferentes perspectivas, sob demanda e variáveis

Um ambiente de inteligência de negócio, portanto, deve suportar o processamento analítico dos gestores do negócio (OLAP), em particular atividades de análise nos níveis descritivo e diagnóstico, de forma a facilitar seu aprendizado sobre a organização e, consequentemente, subsidiar suas decisões.

Entre os desafios trazidos pela perspectiva analítica para os ambientes de BI, e que permanecem como alvo de várias propostas para os ambientes de BI modernos, em que DWs e *data lakes* convivem para dar suporte a todos os níveis de processamento analítico em uma organização, incluindo análises preditivas e


Arquitetura de um ambiente de BI

Um ambiente de **business intelligence** constitui o conjunto de tecnologias para coleta, integração, armazenamento, processamento e visualização de informações de forma a permitir todos os níveis de análise do negócio direcionada por dados, fornecendo um suporte racional para a tomada de decisões organizacionais (ou seja, produzindo e distribuindo informação útil para o tomador de decisão).

A **arquitetura de um ambiente de BI** compreende alguns componentes essenciais, ilustrados na figura a seguir e detalhados adiante:

- um repositório integrado de dados, tradicionalmente representado por uma possível combinação entre *data warehousing* e/ou *data marts*;
- um componente ETL (*extract-transformation-load*), para apoiar os processos de extração dos dados de suas fontes, transformação e carga (*load*) dos dados no repositório integrado (e atualizações contínuas);
- ferramentas de análise que consultam os dados diretamente no repositório ou através de visões multidimensionais, construídas a partir do DW. Entre elas incluem-se ferramentas OLAP (para apoiar os usuários gestores durante o seu processamento analítico *on-line*) e geradores de relatórios gerenciais (pré-definidos ou customizáveis) e *dashboards* ou painéis de controle (para monitoramento dos indicadores de desempenho de dados de forma visual e sintetizada);
- repositório de metadados, incluindo metadados semânticos (que atentam para o significado dos conceitos manipulados), técnicos (formato e tamanho dos campos, por exemplo) e de proveniência (quais as transformações aplicadas e com que valores de parâmetros).

Agora, confira a arquitetura clássica de um ambiente de BI e seus componentes essenciais detalhados nos *slides* a seguir:



Data warehouse

Um DW é o componente central de um ambiente de BI. Ele é basicamente um banco de dados destinado a sistemas de suporte à decisão, cujos dados são armazenados em estruturas lógicas dimensionais. Você entenderá melhor a respeito a seguir, mas essas estruturas lógicas possibilitam o seu processamento analítico por ferramentas OLAP, por geradores de relatórios gerenciais, por painéis de controle (*dashboards*) ou mesmo por outras aplicações mais sofisticadas de *machine learning*.



Inmon (1997), um dos autores mais famosos e tradicionais na literatura sobre BI, define DW como “uma coleção de dados **orientada a assunto, integrado, variante no tempo e não volátil**, para suporte ao processo de tomada de decisões gerenciais”.

Essa definição resume as quatro características principais de um DW, que o definem conceitualmente. Explore os ***cards*** a seguir para conhecê-las.

Interativo

Descrição do interativo

Já Ralph Kimball (2013), um dos autores mais famosos e tradicionais na prática de BI nas organizações, tem uma visão mais pragmática sobre um DW, definindo-o como “uma cópia dos dados transacionais, especificamente estruturados para consultas e análises”, e acrescenta ainda que um “*data mart* é um subconjunto lógico de um *data warehouse*, geralmente visto como um DW setorial”. Tais definições cobrem aspectos complementares à de Inmon sobre esse que é o “coração” (ou seja, o componente principal) de um ambiente de BI.

ETL

Extração, transformação e carga (load) é o componente da arquitetura do ambiente de BI que operacionaliza o processo de alimentação do DW a partir de fontes de dados operacionais. Diversas questões de integração (padronização, heterogeneidade semântica) e tratamento da qualidade dos dados (tratamento de dados faltantes, resolução de inconsistências) são tratadas durante a execução desse processo. Esse processo é executado periodicamente, e sabores mais recentes das arquiteturas de BI (BI

2.0) vêm propondo que a atualização dos dados no BI seja feita de forma cada vez mais frequente, aproximando-se dos dados em tempo real.

Observe um pequeno exemplo de como o processo de ETL deve tratar a heterogeneidade nos dados de diferentes fontes, nesse caso convertendo valores para uniformizar a unidade de medida:

Interativo

Descrição do interativo

Esse processo deve ser fortemente automatizado e ter a sua execução sempre monitorada pelo DBA responsável pelo ambiente. Existe uma série de ferramentas disponíveis (Informatica Powercenter, Apache AirFlow, Oracle Data Integrator, IBM Infosphere Datastage, SSIS, Pentaho Data Integration, Google Cloud Dataflow, AWS Glue, entre outras), que tipicamente implementam essas etapas como um *workflow* de dados.

Veja uma ilustração da arquitetura da ferramenta AWS Glue, incluindo o componente ETL (AWS Glue ETL).

Interativo

Descrição do interativo

As arquiteturas existentes de BI vêm propondo variações no fluxo tradicional das etapas do ETL, criando *pipelines* alternativos em que a ordem das ações pode ser flexibilizada ou customizada em situações específicas. Por exemplo, em um processo ETLT, as ações de transformação dos dados podem ser feitas antes ou depois dos dados carregados do ambiente operacional para o ambiente analítico.

Ferramentas OLAP

Ferramentas OLAP fornecem apoio computacional ao processamento analítico, ambiente de tomada de decisão em uma arquitetura de BI, através da implementação de operadores específicos. Usos típicos de uma ferramenta OLAP são para conduzir análises exploratórias de dados de um DW, inspecionando variáveis de controle (indicadores de desempenho) ou buscando descobrir correlações e/ou tendências que possam fazer surgir algum *insight* no gestor. O objetivo principal dessas ferramentas é suportar a visão multidimensional dos dados através de uma interface gráfica rica e intuitiva, com foco no cruzamento das informações, facilitando o entendimento e a visualização de problemas típicos de suporte à decisão.

Existem diversas implementações, algumas seguindo a abordagem ROLAP (Oracle, Sybase IQ, RedBrick) sobre sistemas de gerenciamento de banco de dados (SGBDs) relacionais, e outras seguindo a abordagem MOLAP (Pilot, Essbase, Gentia).

Os principais operadores analíticos implementados por ferramentas OLAP são:

- *slice and dice* – navegação por meio dos dados na visualização de um cubo, filtrando os registros ou as colunas (*slice*) ou registros e colunas (*dice*) da visualização;
- *pivoting* – “rotação”, mudança na perspectiva de visão (visualiza outra face do cubo);
- *roll-up/drill-down* – navegar do nível de detalhe até o mais alto nível de sumarização dos dados, e vice-versa.

Clique nos *slides* e veja exemplos de aplicação desses operadores analíticos em um cenário de vendas.


Interativo

Descrição do interativo

Dashboards

Dashboards são painéis de controle que monitoram medidas de interesse, tipicamente indicadores de desempenho do negócio. São concisos e pré-definidos, utilizam muitos recursos visuais e servem normalmente como pontos de entrada para análises.

Conheça um exemplo de um *dashboard* no *software* AG MashZone e em PowerBi para um processo intensivo em conhecimento nos *slides* a seguir:



Interativo

Descrição do interativo

Repositório de metadados

Além desses componentes, é importante perceber a necessidade de um conjunto de metadados de todo o ambiente, que é responsável por armazenar informações importantes sobre todos os processos executados no escopo do ambiente de BI. Tais metadados incluem tanto descrições semânticas (que atentam para o significado) quanto técnicas (formato e tamanho) de cada item de dado (tabela, campo, arquivo) mantido no DW e em cada um dos *data marts*.

Outro tipo de metadado essencial são os que descrevem a proveniência dos dados no ambiente de BI, incluindo quando foram realizadas as extrações de dados de cada fonte e quem foi o executor, quais foram as tarefas de transformação aplicadas em cada item de dado (e os valores dos parâmetros utilizados) quais são as visualizações OLAP disponíveis, quais indicadores de desempenho estão sendo monitorados e como são calculados, entre muitos outros.

E os *data lakes*? Evoluindo arquiteturas dos ambientes de BI

Mais recentemente, muitos outros componentes vêm sendo incorporados à arquitetura genérica de um ambiente de BI, como no exemplo de um *dashboard* no *software* AG MashZone, apresentado anteriormente. Note a variedade de repositórios que vêm sendo incorporados ao ambiente de BI moderno (DW, *data marts*, *operational data store* e *data lakes*), coexistindo em um ecossistema em virtude das diferentes naturezas e *timings* de atualização e uso dos dados que neles estão mantidos.




Fique ligado

Além disso, outros componentes vêm sendo adicionados ao ambiente em razão de inúmeras novas aplicações que vêm surgindo para extrair valor a partir dos dados mantidos no ambiente de BI.

Nesse sentido, além de ferramentas mais especializadas para apoio ao processamento analítico e geração customizada de relatórios (*historical analytics*, *advanced analytics*, *operational reports*, *self-service BI*), incluem-se ferramentas de *business activity monitoring* (BAM) e *near-real-time monitoring* e ferramentas de aprendizado de máquina (*machine learning*), que hoje se entende serem responsáveis

por “enriquecer” os repositórios integrados do ambiente de BI com conhecimento aprendido a partir dos dados e, portanto, tornado disponível por todas as ferramentas que consomem os dados dos repositórios.

Veja, a seguir, um exemplo de arquitetura genérica de um ambiente de BI incorporando componentes mais recentes provenientes de iniciativas de transformação digital nas organizações.



O projeto de um *data warehouse*

O processo de desenvolvimento de um DW pressupõe as seguintes etapas (que, como ocorre em qualquer projeto de desenvolvimento de *software*, podem ser executadas seguindo metodologias ágeis ou tradicionais): (a) definição do escopo; (b) levantamento de requisitos e análise do problema; (c) projeto do DW; (d) integração de dados e testes; (e) implantação.

Na etapa de definição do escopo, planeja-se a abrangência do DW dentro da organização (e, conseqüentemente, das análises que poderão ser realizadas sobre ele). O DW pode ser planejado para ser corporativo (e, portanto, abranger toda a organização), departamental/funcional (quando se prioriza alguma área ou departamento da organização) ou por processo (quando se elenca um dos processos de negócio da organização, seguindo uma tendência recente de organizações gerenciadas por processos).

Na etapa de levantamento de requisitos e análise do problema, deve-se levantar junto aos gestores do negócio (futuros usuários ou beneficiários do DW) quais análises devem ser suportadas pelo DW dentro do escopo previamente estabelecido. Em essência, deve-se buscar quais são as medidas de interesse para monitoramento (que tipicamente representam indicadores de desempenho, contabilizados com base em fatos históricos – por exemplo, valor total de vendas ou quantidade de itens em estoque), as perspectivas potencialmente envolvidas na análise de cada medida de interesse (que remetem às dimensões relevantes para o negócio – por exemplo, as vendas de cada produto, ao longo do tempo, para cada canal de venda [físico ou digital], por vendedor) e a granularidade de cada medida a ser monitorada (ou seja, o grão mínimo em que cada indicador será calculado).

Por exemplo, o total de vendas será totalizado por produto ou por cada apresentação de produto (pacote de 1 kg, pacote de 5 kg)? Para cada semana, por dia ou por cada hora do dia? Por cada canal de venda (físico, digital) ou por cada ponto de venda? Por fim, vale ressaltar que é importante buscar sistematicamente variações das análises requisitadas pelos gestores, de forma a prover maior flexibilidade e agilidade para suportar análises não previstas inicialmente, sob diferentes perspectivas.

A etapa do projeto do DW é responsável por especificar o esquema de dados do DW, ou seja, a estruturação adequada dos dados no

repositório para que ele suporte todas as análises previstas (por exemplo, tabelas, colunas e relacionamentos, no caso de um DW hospedado em um SGBD relacional).

De forma geral, o projeto de um DW deve seguir três princípios:

Interativo

Descrição do interativo

Para a especificação do esquema de um DW, utiliza-se o paradigma multidimensional como representação conceitual, o que facilita a compreensão das estruturas de dados que devem ser criadas no repositório (no SGBD que o hospeda). O paradigma multidimensional e as estratégias de especificação do esquema do DW, segundo a modelagem dimensional, serão explicados mais adiante.

Uma vez projetado, passa-se à etapa de desenvolvimento do DW, que pode seguir uma abordagem *top-down* ou *bottom-up*, sempre de forma incremental e iterativa. A abordagem *top-down* visa à construção de um modelo corporativo único e integrado para toda a organização. Todas as fontes de dados são aos poucos integradas a esse repositório (construído com um modelo central), e *data marts* setoriais são incrementalmente disponibilizados como visões extraídas do modelo central. Como vantagem, a abordagem *top-down* naturalmente fornece uma visão global e consistente dos dados corporativos, construindo, por definição, uma visão integrada dos dados no DW.

No entanto, o esforço de integração *a priori* pode consumir mais tempo e recursos para o desenvolvimento e a disponibilização de resultados, requerendo que os ciclos sejam mais longos, o que pode aumentar o risco de conclusão do DW como um todo.

A figura a seguir ilustra a relação entre um DW e *data marts* extraídos a partir dele, seguindo a abordagem *top-down*.

Interativo

Descrição do interativo

Já a abordagem *bottom-up* visa à construção de um *data mart* (setorial) por vez, sem a ambição de serem integrados *a priori* em um modelo central. O desenvolvimento de cada *data mart* é também evolutivo e incremental, em ciclos ágeis, considerando a complexidade do seu escopo, o volume de dados a ser armazenado e o investimento a ser despendido *versus* o valor agregado ao negócio. Apesar da vantagem da abordagem *bottom-up* em disponibilizar resultados mais rapidamente, com ciclos mais curtos, o desafio é garantir uma visão integrada e consistente entre os vários *data marts* existentes.

Seguindo a abordagem *bottom-up*, a relação entre o DW e os *data marts* seria como mostrado na figura a seguir.

Interativo

Descrição do interativo

O paradigma multidimensional

O paradigma multidimensional é a forma como analistas de negócio, gerentes e executivos analisam informações, conforme a figura apresentada a seguir. Nele, o foco é no cruzamento de informações de várias perspectivas importantes para análise de fatos históricos. Esse paradigma facilita o entendimento e a visualização de problemas típicos de suporte à decisão e já se mostrou ser mais intuitivo para o processamento analítico; por isso, é o paradigma utilizado pelas ferramentas OLAP.


Confira algumas perguntas típicas de gestores, segundo o paradigma multidimensional:



Mas qual é a diferença prática do paradigma multidimensional para o “tabular”, seguido pelo modelo relacional tradicional? Considere, por exemplo, os dados sobre o volume de vendas em uma concessionária estruturados como uma tabela:

Modelo	Cidade	Volume de vendas
Mini van	New York	6
Mini van	Los Angeles	5
Mini van	Madson	4
Sports coupe	New York	3
Sports coupe	Los Angeles	5
Sports coupe	Madison	5
Sedan	New York	4
Sedan	Los Angeles	3
Sedan	Madison	2

Segundo o paradigma (ou “visão”) multidimensional, esses mesmos dados poderiam estar organizados logicamente como um vetor bidimensional (ou seja, com duas dimensões ou eixos), como mostrado a seguir:




Nesse exemplo, os valores da medida de interesse (que, no paradigma multidimensional, é denominado “fato”) estão estruturados em um vetor composto a partir das dimensões “modelo” e “cidade”. Cada dimensão é representada por uma categoria, ou seja, um conjunto de elementos distintos (“mini van”, “coupe” e “sedan” na dimensão “modelo”, e “Nova York”, “Los Angeles” e “Madison” na dimensão “cidade”), e os valores do fato “total de vendas” são armazenados nas células desse vetor, ou seja, há exatamente um valor para cada cruzamento entre elementos de cada dimensão. No exemplo, o total de carros do modelo mini van vendidos na cidade de Nova York é 5.

Imagine agora que, em seu processo de análise das vendas, o gestor dessa concessionária deseja detalhar o total de vendas também por fornecedor (ou seja, acrescentar mais uma perspectiva – ou dimensão – de análise). Seguindo a visão lógica relacional, seria necessário acrescentar mais uma coluna à tabela anterior:

Modelo	Cidade	Concessionária	Volume
Mini van	New York	Clyde	6
Mini van	New York	Gleason	6
Mini van	New York	Carr	2
Mini van	Los Angeles	Clyde	3
Mini van	Los Angeles	Gleason	5
Mini van	Los Angeles	Carr	5
Mini van	Madison	Clyde	2
Mini van	Madison	Gleason	4
Mini van	Madison	Carr	3
Sports coupe	New York	Clyde	2
Sports coupe	New York	Gleason	3
Sports coupe	New York	Carr	2
Sports coupe	Los Angeles	Clyde	7
Sports coupe	Los Angeles	Gleason	5
Sports coupe	Los Angeles	Carr	2
Sports coupe	Madison	Clyde	4
Sports coupe	Madison	Gleason	5
Sports coupe	Madison	Carr	1
Sedan	New York	Clyde	6
Sedan	New York	Gleason	4
Sedan	New York	Carr	2
Sedan	Los Angeles	Clyde	1
Sedan	Los Angeles	Gleason	3
Sedan	Los Angeles	Carr	4
Sedan	Madison	Clyde	2
Sedan	Madison	Gleason	2
Sedan	Madison	Carr	3

Já na visão dimensional, esses mesmos dados poderiam ser imaginados ainda como em um vetor, mas agora com três dimensões (ou seja, um “cubo”):




O “cubo”, nesse caso, funciona como uma metáfora visual cognitivamente efetiva e intuitiva para representar a organização dos dados sobre um fato segundo o paradigma dimensional, deixando claro que cada fato requer a construção de um cubo, e em cada cubo todas as dimensões coexistem para todos os valores (células) e são independentes entre si.

E quando há mais dimensões envolvidas?

O paradigma multidimensional é aplicável para um número qualquer de dimensões, ou seja, é perfeitamente possível que a análise do total de vendas de carros pelo gestor da concessionária possa envolver outras dimensões, como, por exemplo as vendas ao longo do tempo, por cor do veículo, e assim por diante. Para mais do que três

dimensões, a metáfora visual que usamos para representar a estrutura dos dados passa a ser chamada de “hipercubo”.

A visualização dos hipercubos (por uma questão de limitação da capacidade visual humana, pois só “enxergamos” em um espaço de até três dimensões) passa, então, a considerar estruturas de dados como um “vetor de cubos” (para quatro dimensões, como na figura a seguir), uma “tabela de cubos” (para cinco dimensões), um “cubo de cubos” (seis dimensões), e assim por diante.



Ou seja, segundo o paradigma multidimensional, os dados de um DW podem ser compreendidos como se estivessem organizados logicamente em vetores multidimensionais. Um vetor multidimensional tem um número fixo de dimensões, e cada dimensão é representada como uma categoria, que compreende um número fixo de elementos. É criado um vetor para cada fato (medida de interesse) a ser analisado, e os valores dessa medida de interesse são armazenados nas células do vetor multidimensional.


A modelagem multidimensional e as estratégias de especificação do esquema do DW

Uma vez compreendido o paradigma multidimensional, pode-se efetivamente especificar o esquema do DW. A modelagem multidimensional utiliza os conceitos do paradigma multidimensional (fatos, dimensões) a fim de representar, de forma clara, eficiente e flexível, a visão multidimensional dos dados.


Fatos são medidas de interesse do negócio que devem ser monitorados e são o foco do processamento analítico. Tipicamente, os fatos constituem indicadores de desempenho definidos pela estratégia do negócio e são medidas obrigatoriamente numéricas e aditivas. Exemplos de fatos incluem: o volume de vendas (que pode ser medido em número de itens ou total em reais), a quantidade de itens em estoque, o volume de transações de cartões de crédito, a quantidade de doses de vacina aplicadas ou o número de óbitos decorrentes de uma pandemia. Características não numéricas (código do vendedor, *status*), não aditivas (preço unitário) ou de granularidade maior do que a definida para o fato em questão (total venda anual) não devem caracterizar fatos.

Dimensões representam pontos de vista, ou perspectivas do negócio, sobre os quais uma organização deseja analisar medidas de interesse. Exemplos de dimensões poderiam ser loja, produto, fornecedor, tempo (em um processo de vendas no varejo) ou paciente, hospital, cidade, fabricante, semana epidêmica (em um cenário de gestão de uma pandemia). Uma heurística comumente utilizada para a definição das dimensões de uma medida de interesse é buscar respostas para as perguntas “quem” (*who*), “quando” (*when*), “onde” (*where*), “o que” (*what*), “por que” (*why*) e “como” (*how*), uma vez que dimensões refletem as perspectivas 5W1H de qualquer cenário.


Uma vez identificados os fatos a serem incorporados ao DW, para cada um buscam-se as dimensões de análise:




No exemplo da concessionária, os fatos e dimensões trabalhados foram:




Em cada dimensão, podem-se definir diferentes níveis de agregação, representados por hierarquias da dimensão. Por exemplo, o total de vendas pode ser calculado por dia e, então, agregado por semana, mês ou ano; da mesma forma, o número de doses de vacina aplicadas pode ser contabilizado por posto de saúde e, então, agregado por bairro, cidade, UF, país. Entenda melhor na imagem a seguir:



A existência de diferentes níveis de agregação em diversas dimensões ortogonais permite que sejam disponibilizadas diversas variações de análise para o gestor, combinando agregações dos diversos níveis entre as dimensões, como na figura a seguir.



Vale ressaltar a importância da dimensão tempo (*when*) na modelagem dimensional de DWs, não apenas por ser uma dimensão obrigatória por definição (afinal, o DW armazena dados históricos), mas também por haver uma série de possibilidades de adicionar características à dimensão tempo, de forma a permitir diversas hierarquias e níveis de agregação: dia da semana, dia útil e feriado, período fiscal, semestre acadêmico, estações do ano, dias festivos (Natal, Carnaval, ...) e eventos (Olimpíadas, Copa do Mundo e eleições), como na figura a seguir.



Estruturas lógicas para implementação de DW em SGBDs

Por definição, DWs são repositórios de dados construídos para responderem consultas gerenciais e, como tais, são tipicamente implementados como bancos de dados gerenciados por SGBDs. Em virtude da sua grande presença no mercado, e por serem frequentemente adotados por organizações de qualquer tamanho (pequeno, médio e grande porte), DWs são majoritariamente implementados em SGBDs relacionais (como Oracle, PostgreSQL, MSSQL, MySQL), nos quais os dados são logicamente estruturados em tabelas (ou relações), nas quais os registros são identificados por restrições de chave primária e relacionados entre si através de chaves estrangeiras. A abordagem de implementação de um DW em um SGBD relacional é chamada de ROLAP (Relational OLAP).

Outra categoria de SGBDs existente no mercado que foi especificamente desenvolvida para suportar o paradigma multidimensional dos ambientes clássicos de BI são os SGBDs multidimensionais. Neles, os dados são armazenados na forma de vetores com *n* dimensões, e há operadores específicos para computar os “hipercubos” de forma eficiente e, assim, pré-processar visões multidimensionais para agilizar a execução dos operadores analíticos em ferramentas OLAP e similares.

Quando um DW é implementado em um SGBD multidimensional na sua forma nativa, diz-se que tal implementação seguiu a abordagem MOLAP (multidimensional OLAP). Um exemplo de SGBD multidimensional é o SSAS. Outros SGBDs relacionais também funcionalidades para prover uma interface de acesso multidimensional aos dados armazenados na forma tabular, como é o caso do Oracle MOLAP e PostgreSQL Cube.

Utilizando uma abordagem ROLAP, cada fato e dimensão do esquema de um DW é implementado em uma tabela. Em uma tabela de fatos, cada medida é um atributo (ou coluna), e são adicionadas colunas (chaves estrangeiras) para referenciar cada uma das dimensões que descreve esse fato. A chave primária da tabela fato é uma chave *surrogate* (um código sequencial e sem significado), mas sabe-se que a composição das chaves estrangeiras é única (não deve existir mais de um registro na tabela fato com valores idênticos das chaves de todas as dimensões).

A granularidade do fato é, portanto, determinada pela combinação das colunas de chave estrangeira da sua tabela fato. Tabelas fato tipicamente têm alta cardinalidade (podendo chegar a ter bilhões ou trilhões de registros, dependendo da granularidade definida), e por isso não deve armazenar informação redundante (como textos, valores nulos ou registros com valores de medida zerados).

Veja um exemplo de uma tabela fato:

Fato_Venda
data_PK
produto_PK
valor_vendido
unidades_vendidas
custo_vendido

Na abordagem MOLAP, um fato é implementado por um vetor composto por elementos representando cada medida de interesse desse fato e elementos adicionais que referenciam campos identificadores dos vetores que implementam cada dimensão.

fato_venda (valor_vendido, unidades_vendidas, custo_vendido, id_data, id_produto, id_loja)

Quanto às dimensões, na abordagem ROLAP cada tabela dimensão deve descrever essa perspectiva do negócio da forma mais completa possível, portanto a existência de atributos descritores (preferencialmente categóricos) e/ou textuais – com linguagem clara – é recomendada. É importante que todas as descrições sejam completas e livres de ambiguidade (evitando abreviações, códigos e jargão específico de apenas uma área da organização ou parte do negócio).

Deve-se lembrar que o DW tem o potencial de servir análises de outras áreas e processos da organização, de forma integrada. Os campos descritores serão tipicamente usados como cláusulas de filtro para agrupamento dos dados ou mesmo em títulos de relatórios; portanto, a utilização de terminologias uniformizadas ou de um modelo conceitual (ou ontologia) de referência é extremamente recomendável para que as consultas e o relatório gerados tenham conteúdo legível, inteligível e sem múltiplas interpretações para um mesmo termo.

Em uma tabela dimensão, a chave primária deve ser simples (recomenda-se um *surrogate*, ou código sequencial sem significado). Em geral, os registros em tabelas dimensão não dependem do tempo, mas, sempre que há atualização nos dados operacionais, devem ser criadas versões dos registros atualizados, com campos que permitam delimitar a janela de tempo em que esse registro tem validade.

Para aumentar o desempenho, é comum que tabelas de dimensão sejam desnormalizadas (violando um dos princípios do modelo relacional tradicional), com hierarquias implícitas (e, portanto, com dados de algumas colunas repetidos entre registros). O impacto da desnormalização não deve ser grande, uma vez que as operações de consulta tipicamente excedem, e muito, em frequência as operações de atualização dos registros das tabelas dimensão.

Veja um exemplo de tabela de dimensão:

Dimensão_Produto
Produto_PK
descrição
marca
categoria
departamento
tipo_embalagem
conteúdo_gordura
tipo_diet
peso
peso_unidade_medida
tipo_armazenamento
...

Tipos de esquema multidimensional

Durante o projeto de um DW, os fatos e dimensões do esquema resultante podem ter sido dispostos e inter-relacionados seguindo diferentes conformações, caracterizando três tipos distintos de esquemas DW: estrela, floco de neve e constelação de fatos. Para descrever as diferenças entre eles, vamos assumir a abordagem ROLAP.

Para projetar um DW seguindo um esquema estrela, para cada fato deve haver apenas uma tabela (sem redundância alguma), e essa tabela fato deve estar relacionada a exatamente uma tabela para cada dimensão que descreve aquele fato. Isso determina que as dimensões sejam necessariamente desnormalizadas, ou seja, as hierarquias de cada dimensão são representadas por atributos na tabela dimensão.

As vantagens do esquema estrela são que as dimensões e os fatos são claramente identificados no esquema, a visualização é simples, o esquema é simétrico, o que facilita a flexibilidade para implementar novas análises, e é extremamente eficiente, por ter caminhos curtos de navegação no banco de dados (através das junções).

Interativo

Descrição do interativo



Refleta

Agora que você conheceu um pouco do contexto geral de ambientes de BI, chegou a hora de exercitar o cérebro e desenvolver ainda mais seu olhar crítico.

Com base no que estudamos nesta aula, reflita: como os ambientes operacional e analítico convivem na empresa em que você trabalha ou trabalhou? As estratégias de gestão organizacional em curso são orientadas a dados?



Referências

Clique aqui para acessar as referências e créditos desta aula.



BLUE GRANITE. **Data lakes in a modern data architecture**. [s.l.: s.n.], 2020. Disponível em: <https://www.bluegranite.com/data-lakes-in-a-modern-data-architecture-ebook>. Acesso em: 2 jun. 2023.

INMON, William H. **Como Construir o Data Warehouse**. Rio de Janeiro: Campus, 1997.

KAPLAN, R.; NORTON, D. **A execução premium**: a obtenção de vantagem competitiva através do vínculo da estratégia com as operações do negócio. Rio de Janeiro: Elsevier, 2008.

KIMBALL, R, **The Data Warehouse Toolkit**: The Definitive Guide to Dimensional Modeling, Third Edition. Indianápolis: Wiley; 2013.

LAUDON, K. C.; LAUDON, J. P. **Management information systems**: managing the digital firm. 16. ed. [s.l.]: Pearson Education, 2019.

MLLER, C. J. **Planejamento estratégico, indicadores e processos**: uma integração necessária. São Paulo: Atlas, 2013.

ROSS, M.; KIMBALL, R. **The data warehouse toolkit**: the definitive guide to dimensional modeling. [s.l.]: John Wiley & Sons, 2013.

ZIEGLER, P.; DITTRICH, K. R. Three decades of data intecration: all problems solved? In: JACQUART, R. **Building the information society**: IFIP 18th World Computer Congress

Topical Sessions 22-27 August, 2004, Toulouse, France.
Toulouse: Springer, 2004. p. 3-12.

Banco de imagens Envato, Freepik, Pexels, Pixabay e
Shutterstock.