



AULA 2

Qualidade de dados



Objetivos de aprendizagem da aula

Ao final desta aula, você irá:

- Explicar “Dados Mestre e de Referência”, uma das áreas de conhecimento do DMBOK relacionadas à qualidade de dados.
- Explicar “Metadados”, uma das áreas de conhecimento do DMBOK relacionadas à qualidade de dados.
- Explicar “Qualidade de Dados”, uma das áreas de conhecimento do DMBOK relacionadas à qualidade de dados.
- Explicar aspectos de “linhagem de dados” (proveniência).
- Exemplificar aspectos de Pessoas (estrutura), de Processos (gestão) e de Métricas (Governança) para qualidade de dados.

Que história é essa?

Nesta segunda aula, será apresentado o tema qualidade de dados e aspectos para a sua gestão e governança. Serão descritas três áreas de conhecimento do Data Management Body of Knowledge (DMBOK) relacionadas ao tema (dados- mestre e dados de referência, metadados e qualidade de dados). Entenderemos por que o registro da linhagem de dados é importante para a sua qualidade. Ao final, iremos aprender que aspectos de pessoas, processos e métricas são mais relevantes para a gestão e governança da qualidade de dados.

A qualidade de dados sempre foi um tema muito importante. Muitas decisões tomadas em empresas são baseadas em dados, por exemplo, criados a partir dos seus sistemas internos. Problemas relacionados, por exemplo, ao estoque de materiais e à produção dos colaboradores da empresa podem ser identificados a partir da coleta

e análise de dados. Da mesma forma, em uma esfera de governo (municipal, estadual ou federal), são necessários dados de qualidade prestação de serviços e definição de políticas públicas.

Dados também são fundamentais para o mundo acadêmico. Sem dados com qualidade não é possível desenvolver pesquisas empíricas.

Recentemente, a quantidade de dados disponíveis para tomada de decisão aumentou significativamente. Empresas agora podem mais facilmente complementar os seus próprios dados com dados gerados externamente, por exemplo, por redes sociais ou dados abertos fornecidos por governos por meio da internet.



Mas o que é qualidade de dados? Uma quantidade muito grande de dados pode mitigar problemas de qualidade de dados? Como avaliar se um determinado conjunto de dados tem qualidade ou não?

A título de exemplo, vamos considerar um conjunto de dados sobre clientes de uma rede de lojas que tem operações em várias cidades do Brasil. De cada cliente há informações sobre o CPF, o nome, a data de nascimento e a cidade onde a última compra foi realizada. Vamos considerar que cada consumidor tenha o seu próprio CPF e que haja, nesse conjunto de dados, 10 mil clientes.



Que critérios poderiam ser utilizados para avaliar a qualidade desse conjunto de dados?

Vamos considerar que esses dados foram disponibilizados na forma de uma planilha eletrônica com 10 mil linhas e quatro colunas. Uma possível forma de verificar a qualidade desse conjunto de dados é avaliar coluna a coluna.

Por exemplo, que valores são esperados para a coluna CPF? Clique nos *slides* e conheça os cinco critérios esperados.

Interativo

Descrição do interativo

Os critérios de qualidade também podem ser definidos para as colunas nome, data de nascimento e cidade de última compra. Por exemplo, o nome não pode ter dígitos decimais, a data precisa ser correta e respeitar alguns limites (não pode ser uma data no futuro), e a cidade informada precisa ser uma dos cerca de 5.570 municípios existentes no Brasil.

Apresentamos, a seguir, algumas áreas de conhecimento preconizadas pelo DMBOK que estão relacionados à gestão da qualidade dos dados e à sua respectiva governança.

Dados de referência e dados-mestre

Dados de referência são utilizados para classificar ou categorizar outros dados. Uma empresa pode definir que unidades de medida vai utilizar para seus produtos ou como vai classificar os seus fornecedores. Por outro lado, há dados de referência que são definidos externamente à empresa.

Por exemplo, o Instituto Brasileiro de Geografia e Estatística (IBGE) define que a cor de uma pessoa pode ser apenas amarela, branca, indígena, parda ou preta. A utilização de referências externas é interessante e deve ser adotada quando for possível, pois permite a comparação e a utilização de dados de várias fontes – contanto que estas utilizem os mesmos critérios de classificação. Outro exemplo são os códigos de identificação de países. A International Organization for Standardization (ISO) define códigos de duas e de três letras para todos os países existentes. Os dados-mestre são aqueles que representam os objetos, as entidades e as atividades de uma empresa em particular, por exemplo, de fornecedores, clientes e colaboradores. Fica claro, portanto, que os dados de referência contribuem para a qualidade dos dados-mestre.



Segundo o DMBOK, um dos principais objetivos da gestão de dados de referência e dados-mestre é permitir o compartilhamento de ativos

de informação dentro da organização. Dessa forma, todos contariam com orientações precisas e confiáveis para utilização de dados compartilhados (dados-mestre) e classificações (dados de referência) a serem utilizadas para novos conjuntos de dados que venham a ser criados.

Metadados

Metadados são dados que descrevem dados. Quanto melhor e mais completa for essa descrição, melhor serão os critérios a serem utilizados para verificação da sua qualidade. No exemplo do CPF, foram identificadas cinco condições que devem ser atendidas para que os valores dessa coluna sejam considerados de qualidade. Não é possível avaliar a qualidade de um conjunto de dados sem ter conhecimento dos seus metadados.

Outro benefício importante da existência de metadados para a organização é o compartilhamento da mesma definição entre todas as suas áreas. Considere, por exemplo, uma coluna com a informação de endereço de clientes. A área de logística de uma empresa pode considerar que esse endereço é aquele referente à entrega de produtos adquiridos pelo cliente; já a área de contas a receber pode considerar que o endereço informado é para enviar o boleto de cobrança.



Fique ligado

Mesmo índices estabelecidos e utilizados para a gestão e a governança de empresas precisam ser claramente definidos para que possam ser entendidos da mesma forma por todos que trabalham nelas.

Por exemplo, há de se definir claramente o que é o índice de produtividade ou a taxa de rotatividade de pessoal em uma empresa, pois há várias formas de calcular esses índices.

Exemplos de metadados

Sistema BR-Brasil - Boletins de Ocorrências em Rodovias Federais

O sistema BR-Brasil é um sistema desenvolvido pelo Departamento de Polícia Rodoviária Federal (DPRF) que visa reunir todos os dados gerados em termos de segurança e trânsito, possibilitando a grande maioria dos serviços funcionarem associados às atividades da PRF e disponibilizando seus registros de dados em todo o país. Desde sua implementação, o sistema tem sido amplamente utilizado e reconhecido a nível nacional.

Locais e recursos

Modelo Entidade Relacionamento

Explorar

Diagrama de Dados

Explorar

Ocorrências 1º semestre de 2007

Explorar

Informações Adicionais

Campo	Valor
Autor	Departamento de Polícia Rodoviária Federal
Mantenedor	Ministério da Justiça
Última Atualização	30 de Junho de 2017, 00:40 (UTC-03:00)
Criado	30 de Agosto de 2013, 17:58 (UTC-03:00)
Cobertura Temporal	2007 a 2014
Granularidade Geográfica	Municipal
Periodicidade	Semestral
VCGE	Transporte Rodoviário [http://vocab.e-gov.br/2011/03/vcge#transporte-rodoviario] Segurança Pública [http://vocab.e-gov.br/2011/03/vcge#seguranca-publica]

Segundo o DMBOK, a gestão de metadados é responsável pela criação, manutenção, difusão e disponibilização de acesso às definições dos dados utilizados por uma empresa. Metadados são essenciais para conjuntos de dados (*datasets*) abertos. Nas imagens, são apresentados metadados de uma fonte de dados disponível no Portal Brasileiro de Dados Abertos (dados.gov.br).

Fonte: <https://dados.gov.br/dataset/acidentes-rodovias-federais>

Há várias informações que podem ser utilizadas para descrição de conjuntos de dados, clique nas abas abaixo para conhecer algumas delas.

Nome

- O nome que brevemente descreve o conteúdo dos dados.

Versão

- Um conjunto de dados pode ter várias versões.

<https://pucrio.grupoa.education/plataforma/course/2799406/content/55351102>

4/10

Descrição	↓
- A descrição detalhada do conjunto de dados.	
Estrutura	↓
- A estrutura dos dados contidos no conjunto de dados, por exemplo: os dados podem ser compostos de uma ou mais planilhas que estão relacionadas umas às outras.	
Tabelas	↓
- Se os dados utilizarem uma estrutura de tabela, devem ser descritas as colunas existentes, seus tipos e os domínios.	
Chaves identificadoras e de ligação	↓
- Cada conjunto de dados pode ter uma ou mais colunas que identificam cada linha desse conjunto; essas chaves identificadoras são semelhantes às chaves primárias descritas do modelo relacional de dados. - Cada conjunto de dados pode ter coluna que é de um dado conjunto para outro conjunto de dados; essas chaves de ligação são semelhantes às chaves estrangeiras descritas no modelo relacional de dados.	
Granularidade	↓
- A granularidade pode indicar qual é o nível de agregação dos dados, por exemplo: se os dados forem de população, cada linha de uma planilha pode indicar a população de um município de um estado ou de uma região do país. Uma mesma planilha pode ter dados de mais de uma granularidade. Nesse caso, seria necessário mais uma coluna nessa planilha para indicar o nível de granularidade de cada linha: nível município, nível estado ou nível região.	
Temporalidade	↓
- A temporalidade vai indicar a que período de tempo os dados se referem, por exemplo: uma planilha didática pode ter dados do último dia útil do mês anterior ou de dados do primeiro dia útil de cada um dos últimos 12 meses.	
Origem	↓
- A origem dos dados é muito importante e precisa ser claramente conhecida, por exemplo: pode ser uma coleta de dados primários ou dados fornecidos por um serviço de informação adquiridos por uma empresa.	
Licença de uso	↓
- O conjunto didático que está sendo descrito pode ter uma licença de uso ou não. Existem licenças que obrigam, por exemplo, a citação correta da fonte, uma vez que esses dados venham a ser utilizados por terceiros.	
Transformações realizadas	↓
- Um determinado conjunto de dados pode sofrer várias transformações, por exemplo: os dados originais podem ter sido agregados segundo algum critério. Da mesma forma,	

dados que estavam ausentes podem ter sido preenchidos também segundo algum critério.

Comentários (“conversational metadata”)



- Esse último item de descrição é de livre preenchimento, não estruturado. Ele pode conter complementos à descrição estruturada com comentários pertinentes para quem irá utilizar o conjunto de dados.

Qualidade de dados

O DMBOK tem uma área de conhecimento inteiramente dedicada à qualidade de dados. A gestão da qualidade de dados, de acordo com a Dama International (2017, p. 451, tradução nossa), é responsável pelo [...] planejamento, implementação e controle de atividades que aplicam técnicas de gestão de qualidade aos dados, a fim de garantir que estejam aptos para consumo e atendam às necessidades dos consumidores de dados.

Clique nas abas abaixo para conhecer mais.

Os objetivos de gestão devem ser:




- Desenvolver uma abordagem para adequar os dados à finalidade com base nos requisitos dos consumidores de dados.
- Definir padrões, requisitos e especificações para controles de qualidade de dados como parte do ciclo de vida dos dados.
- Definir e implementar processos para medir, monitorar e relatar os níveis de qualidade dos dados.
- Identificar e promover oportunidades para melhorar a qualidade dos dados, por meio de melhorias de processos e sistemas.

Para que esses objetivos possam ser atingidos, é necessário realizar atividades para:



- Definir dados de alta qualidade.
- Definir uma estratégia de qualidade de dados.
- Definir o escopo da avaliação inicial.
- Realizar a avaliação inicial da qualidade dos dados.
- Identificar e priorizar melhorias.
- Desenvolver e implantar operações de qualidade de dados.



Qualidade de dados

Nesta videoaula, conheceremos mais como resolver ou, pelo menos, mitigar problemas com a qualidade de dados.




Linhagem de dados

A linhagem, no sentido mais amplo, indica a relação entre uma série de gerações de indivíduos (pessoas, animais, objetos, dados, etc.), ou seja, sua linha de parentesco. Ela pode ser representada, por exemplo, como uma árvore genealógica que indica todos (ou parte) os antecessores que deram origem a um determinado indivíduo.



Aprenda mais

Entenda mais a linhagem de dados.



A existência do registro da linhagem dos dados é uma das condições necessárias para a garantia da qualidade dos dados. Erros e problemas existentes em um determinado conjunto de dados podem ser mais bem avaliados, pois a linhagem indicará todas as transformações realizadas nas versões anteriores que podem, por sua vez, serem auditadas na busca da causa raiz de um determinado problema de qualidade de dados. Por exemplo, a utilização de dados duvidosos ou sobre os quais não se conhece a qualidade e que, portanto, não se conhece a sua linhagem, pode levar a conclusões e decisões incorretas.

Existe um padrão recomendado pela W3C para a descrição da proveniência de dados chamado **PROV**. Os conceitos de proveniência e a linhagem de dados são idênticos para fins dessa descrição.

Para Groth e Moreau (2013, *on-line*, tradução nossa), a proveniência “[...] são informações sobre entidades, atividades e pessoas envolvidas na produção de um dado ou uma coisa que podem ser usadas para formar avaliações sobre sua qualidade, confiabilidade ou confiabilidade”.

PROV



Aprenda mais

Os elementos básicos de um diagrama PROV são apresentados a seguir. As entidades podem ser documentos, planilhas, tabela de um banco de dados, entre outras.

Interativo

Descrição do interativo

[Clique aqui](#) para realizar a leitura (em inglês) e aprender mais sobre PROV.

Pessoas, processos e métricas

Para a definição de pessoas, processos e métricas relacionados à qualidade de dados de uma empresa, é necessário existir um pleno alinhamento estratégico em vários níveis.

Por exemplo, as diretrizes e o planejamento da área de TI devem estar alinhados aos da empresa; da mesma forma, as diretrizes que orientam a qualidade de dados na empresa devem estar alinhadas às diretrizes e ao planejamento estratégico da TI.



Fique ligado

Uma vez que esse alinhamento para a área de dados esteja definido, vamos abordar três aspectos organizacionais necessários para implementar essa área: as pessoas, os processos e as métricas.

O desenho da estrutura organizacional responsável pela qualidade de dados pode ser diverso. Um modelo é considerar que existe apenas uma área da empresa responsável por essa qualidade. Esse não é um cenário muito realista, pois múltiplas áreas da empresa utilizam dados de origem interna e externa. No caso de dados que são incorporados a repositórios disponíveis para toda a empresa (ex: um *data lake*), é possível imaginar que a área de TI faça algum controle de qualidade.



Mantendo o foco

A área de TI de uma empresa também é responsável pelos bancos de dados, e o setor encarregado dos sistemas e das aplicações deve zelar pela qualidade de dados que o seu sistema gera e utiliza. Uma forma de promover a qualidade de dados, seja em um desenho centralizado ou não centralizado, é promover a capacitação de pessoas responsáveis pela aquisição, captura, gestão, armazenamento e divulgação de dados da empresa em todas as áreas.

A maturidade de processos relativos à qualidade de dados pode ser determinante para o sucesso dessas atividades. Como vimos anteriormente, é necessário haver metadados, pois sem eles não há referência de qualidade para os dados. Nesse quesito, a modelagem de dados com metadados pode contribuir decisivamente para a sua qualidade.

Os metadados definidos precisam passar por algum tipo de verificação ou avaliação periódica em um ciclo de melhoria contínua. Essa validação pode ser realizada por equipe interna na empresa ou por um time externo.

Outro aspecto importante são os processos relacionados às boas práticas para manuseio de dados por parte de sistemas e aplicações.

Os dados gerados por sistemas internos precisam ter a sua qualidade garantida e verificada regularmente. Não é incomum encontrar nas empresas sistemas que geram dados inconsistentes ou mesmo conflitantes, dependendo da fonte de informação utilizada pela empresa.



A governança, no que se refere à qualidade de dados, pode ser iniciada por meio de reuniões regulares realizadas com a alta direção da empresa ou os seus representantes para acompanhamento das atividades planejadas e de métricas estabelecidas para caracterização não apenas do avanço dessas atividades, mas também dos seus efeitos.

As métricas precisam ser adequadas às iniciativas que estão em desenvolvimento. É comum fazer uma medição antes do início das atividades, muitas vezes conhecido como *basiline*, de tal forma que seja possível avaliar o resultado de tais ações. Essas métricas podem variar, mas seguem algumas sugestões:

- Percentual de dados de referência definidos.
- Grau de conhecimento dos colaboradores acerca dos dados de referência.
- Percentual de dados mestre definidos.
- Grau de conhecimento dos colaboradores acerca dos dados-mestre.
- Percentual de dados com metadados definidos.
- Grau de conhecimento dos colaboradores acerca dos metadados.



Reflita

Para que os objetivos da gestão possam ser atingidos, é muito importante, entre outros, garantir a qualidade dos dados.

Chegou a hora de refletir: como você pode garantir que na sua empresa os dados utilizados para tomada de decisão são confiáveis?



Referências

Clique aqui para acessar as referências e créditos desta aula.



DAMA International. **DAMA-DMBOK**: data management body of knowledge. New York: Technics Publications, 2017.

GIL, Y.; MILES, S.; BELHAJJAME, K.; DEUS, H.; GARIJO, D.; KLYNE, G.; MISSIER, P.; SOILAND-REYES, S.; STEPHAN, Z. PROV model primer. **World Wide Web Consortium**, p. 1-17, Apr. 2013.

GROTH, P.; MOREAU, L. (ed.). PROV-overview: an overview of the PROV family of documents. **World Wide Web Consortium, on-line**, Apr. 2013. Disponível em: <https://www.w3.org/TR/prov-overview>. Acesso em: 21 jun. 2023.

Banco de imagens Pexels, Pixabay, Envato, Freepik e Shutterstock.