



AULA 1

Introdução e aplicações de ciência de dados



A PROFESSORA

Tatiana Escovedo

Professora do Departamento de Informática da PUC-Rio, onde coordena cursos de pós-graduação *lato sensu* e colabora com pesquisas nas áreas de ciência de dados e engenharia de *software*. Atua como gerente da área de tecnologia, gestão de dados e conhecimento na diretoria de comercialização e logística da Petrobras. É doutora em engenharia elétrica, na área de métodos de apoio à decisão, e mestre em informática, na área de engenharia de *software*, pela PUC-Rio, e autora dos livros *Introdução a Data Science – algoritmos de Machine Learning e métodos de análise; Jornada Java*; e *Jornada Python*.



CONVIDADO

Arthur Barbosa

Atua como coordenador de gestão de dados e *analytics* da diretoria de comercialização & logística da Petrobras, onde é responsável por gerir a integração de informações de negócio e o portfólio de soluções analíticas e difundir a cultura *Data Driven* e de transformação digital. É graduado em ciência da computação e graduando em ciências econômicas pela UFRJ.

Objetivos de aprendizagem da aula

Ao final desta aula, você irá:

- Compreender contextualização, habilidades necessárias, desafios, técnicas e ferramentas relacionadas no contexto de ciência de dados.
- Diferenciar os tipos de problemas de ciência de dados relacionados a *Machine Learning* (ML) (aprendizado supervisionado x não supervisionado; problemas de classificação, regressão, clusterização e associação).
- Entender as 7 etapas de um projeto de ciência de dados e as atividades esperadas em cada uma delas.

Nesta primeira aula, teremos o primeiro contato com o conceito de ciência de dados. Contextualizaremos o cenário atual e falaremos sobre desafios, técnicas e ferramentas utilizadas em ciência de dados. Também aprenderemos a diferenciar os tipos de problemas de ciência de dados relacionados a *Machine Learning* (aprendizado supervisionado x não supervisionado) e falaremos das características dos problemas de classificação, regressão, clusterização e associação. Por fim, iremos entender as 7 etapas de um projeto de ciência de dados e as atividades esperadas em cada uma delas.

Vamos lá?

Que história é essa?

Banco de dados ou “bando” de dados?

Nosso cenário mundial atual é caracterizado pela criação e crescimento de inúmeras bases de dados, diariamente, em fluxo contínuo e em velocidade exponencial. Uma pesquisa realizada pela *Forbes* aponta que, no ano de 2017, estimava-se que cerca de 90%

dos dados armazenados na *web* tivessem sido gerados nos dois anos anteriores. Segundo outra pesquisa, realizada pela empresa DOMO, em 2021, a internet já alcançava mais de 60% da população mundial, e a quantidade total de dados gerados no mundo foi estimada em cerca de 79 zettabytes (79 trilhões de GB).

Esses dados são gerados, em sua maioria, de aplicativos e *websites* de redes sociais, bancos, *e-commerce* e sistemas internos de empresas, formando o que conhecemos como *Big Data*, ou seja, dados de alto volume, alta velocidade e/ou alta variedade.

Para processar e obter informação útil a partir desses dados, é necessário automatizar diversas tarefas de coleta, processamento e análise de dados para tomada de decisão, uma vez que, devido ao grande volume de dados disponível, torna-se inviável realizar essas tarefas manualmente. Nesse contexto, surge a **inteligência artificial, que visa a simular o comportamento de um cérebro humano utilizando máquinas**.


De forma mais técnica, e de acordo com a definição do Gartner Group, *Data Mining* (mineração de dados) é o processo de descoberta de significativas correlações, padrões e tendências em grandes volumes de dados por meio do uso de técnicas e reconhecimento de padrões, estatística e outras ferramentas matemáticas. Para encontrar padrões, o processo de *Data Mining* utiliza muitas vezes as técnicas de *Machine Learning* (aprendizado de máquina), uma subárea da inteligência artificial que se concentra na descoberta de padrões ou de fórmulas matemáticas que expliquem o relacionamento entre os dados e estuda formas de automatização de tarefas inteligentes que seriam difíceis de ser realizadas por humanos.

Aprenda mais

Conheça mais sobre o **Gartner Group** conferindo o *site* oficial. Para acessá-lo, [clique aqui](#).

Apesar de as técnicas de reconhecimento de padrões e de análise exploratória de dados utilizadas em *Data Mining* e *Machine Learning* serem antigas e, em sua grande parte, provenientes da estatística, elas só passaram a ser efetivamente usadas para exploração de dados nos últimos anos, devido a fatores como: maior volume de dados disponível, criação e popularização de *Data Warehouses* (grandes armazéns de dados, com arquitetura de dados voltada para a tomada de decisão), recursos computacionais potentes, forte competição empresarial e criação de diversos *softwares*.

O conceito de *Data Science* (ciência de dados), por sua vez, é mais amplo: refere-se à coleta de dados de várias fontes para fins de análise, com o objetivo de apoiar a tomada de decisões, utilizando geralmente grandes quantidades de dados, de forma sistematizada. Quase sempre, além de olhar para os dados passados para entender o seu comportamento (atividade conhecida como *Business Intelligence* – BI), deseja-se também realizar análises de forma preditiva, por exemplo, utilizando técnicas de *Data Mining* e/ou *Machine Learning*.



Dessa forma, é possível gerar um produto que agregue valor ao negócio, ou seja, aplicar a ciência para aprender com os dados, e não simplesmente executar os algoritmos ou técnicas de *Business Intelligence* ou *Machine Learning*.

Para trabalhar com ciência de dados, como o nome já indica, precisamos de dados, e quanto mais dados, melhor (desde que sejam dados com qualidade), pois será mais fácil encontrar os padrões ou fórmulas matemáticas que os expliquem. Esses dados podem ser oriundos de fontes (estruturadas ou não) como planilhas, documentos, imagens, bancos de dados (relacionais ou não) e *Data Warehouses*. Na prática, eles têm qualidade ruim, sendo necessário gastar um tempo considerável na sua preparação, limpeza e enriquecimento.

Fique ligado!

Para ser capaz de realizar todas as etapas necessárias para efetivamente gerar valor ao negócio a partir de dados brutos, consideramos que o profissional de ciência de dados deve ter uma formação multidisciplinar, unindo disciplinas como estatística, programação, aprendizado de máquina, banco de dados e inteligência artificial.

Aplicações de ciência de dados

Você já parou para pensar sobre como a ciência de dados tem contribuído com a evolução do mundo?

Exemplos de aplicações da ciência de dados no mundo

Para ajudá-lo nessa reflexão, a seguir ouça o *podcast* que preparamos para você.

▶


0:00 / 2:16

🔊

⋮

Viu só?

Nesse *podcast*, trouxemos apenas alguns exemplos da aplicação da ciência de dados no mundo. Caso você fique curioso e queira conhecer outras áreas beneficiadas, não fique parado. Pesquise, busque, invista em seu conhecimento.




Knowledge discovery in databases

É importante observar que, em problemas de ciência de dados, o valor dos dados armazenados está diretamente ligado à capacidade de se extrair conhecimento de alto nível a partir deles, ou seja, gerar, a partir dos dados brutos, informação útil para tomada de decisão (conhecimento).

Fique ligado!

O processo *knowledge discovery in databases (KDD)* é uma das etapas que mais agrega valor para a tomada de decisão. Ele consiste na transformação de dados brutos em informações úteis, gerando, assim, conhecimento para uma organização.

Para tal, são comumente utilizados sistemas de apoio à decisão, que auxiliam os usuários na tomada de decisão.



KDD pode ser definido como um processo de várias etapas, não trivial, interativo e iterativo, para identificação de padrões compreensíveis, válidos, novos e potencialmente úteis a partir de grandes conjuntos de dados.

Essa definição mostra que a descoberta de conhecimento é um processo complexo e composto de várias etapas, que necessita do envolvimento de profissionais como o analista de dados e/ou o cientista de dados para analisar os dados e construir os modelos e o especialista de domínio para interpretar os resultados. Para tal, assume-se como premissa que há um conjunto de dados também conhecido por *dataset*, que pode envolver n atributos (também chamados de campos, colunas e variáveis), e esses atributos representam o hiperespaço. Vale ressaltar que quanto maior o valor de n e o número de registros (também conhecido por linhas, transações, exemplos e instâncias), maior é o conjunto de dados a ser analisado, e geralmente maior é a sua complexidade.

Mantendo o foco

Em KDD, pode-se dividir o processo de construção dos modelos em duas grandes etapas, que são conhecidas por diversos nomes na literatura. Costuma-se dizer que se está **aprendendo** – ou então treinando, construindo, formulando, induzindo um modelo de conhecimento– a partir de um conjunto de dados quando se procura por padrões nesses dados, em geral utilizando - se um ou mais algoritmos de *Data Mining* ou *Machine Learning*. Por fim, quando se faz uma estimativa– ou então teste, predição– dos valores desconhecidos para atributos do conjunto de dados, diz-se que o modelo está sendo **aplicado**.

Para facilitar o seu entendimento, confira um exemplo que preparamos para você.



Interativo

Descrição do interativo

Portanto, é possível dizer que a principal etapa do processo de KDD é o aprendizado, ou seja, a busca efetiva por conhecimentos novos e úteis a partir dos dados. É importante lembrar que todo processo de KDD deve ser norteado por objetivos claros. Devem-se definir previamente a tarefa a ser executada e a expectativa dos conhecedores do domínio (por exemplo, taxa de erro aceitável, necessidade de o modelo ser transparente para os especialistas, natureza das variáveis envolvidas, etc.).


Mantendo o foco

Vale a pena ressaltar que **KDD é um processo**, e focar apenas nos resultados obtidos pode levar à desconsideração da complexidade da extração, organização e apresentação do conhecimento extraído. É um processo muito **mais complexo que 'simplesmente' a descoberta de padrões interessantes**: envolve o entendimento do problema e o estabelecimento dos objetivos, a negociação com os 'donos' dos dados que se quer analisar, os recursos computacionais e profissionais disponíveis, a dificuldade de trabalhar com dados incompletos, inconsistentes e/ou incertos e a apresentação adequada dos resultados para os interessados.

Tipos de dados

A facilidade de trabalhar com dados está ligada a quanto eles são estruturados. Dados **não estruturados**, como, por exemplo, arquivos, fotos e *tweets*, são mais difíceis de se trabalhar do que dados **estruturados**, como planilhas e tabelas de um banco de dados. Há ainda os dados **semiestruturados**, como os *e-mails*, compostos por campos estruturados (como data de envio, remetente, destinatário e título) e não estruturados (como anexos e a mensagem em si).

Estima-se que pelo menos 80% dos dados do mundo sejam não estruturados, o que traz uma complexidade adicional para utilizá-los para extração de conhecimento. Os dados estruturados são mais comumente armazenados em bancos de dados relacionais e *Data Warehouses*, ao passo que os dados não estruturados podem ser armazenados em *Data Lakes*.



Quando falamos de repositórios de dados, em geral falamos de bancos de dados relacionais, *Data Warehouses* e *Data Lakes*. De forma simplificada, um banco de dados relacional armazena dados em tabelas relacionadas entre si. Observe a diferença entre os repositórios *Data Warehouse* e *Data Lake*:


Data Warehouse


vs.

Data Lake

Data Warehouse

É um repositório de dados orientado por assunto, integrado, não volátil, variável com o tempo, que favorece a extração de relatórios e análises para apoiar as decisões gerenciais.





Data Lake

É um repositório único de dados brutos da empresa que utiliza processamento e armazenamento distribuído devido ao grande volume de dados que comumente armazena.


Nos bancos de dados relacionais e nos *Data Warehouses*, os dados são limpos e organizados em um único esquema antes do seu armazenamento, e a análise é feita por meio de consultas diretamente no banco de dados (relacional ou *Data Warehouse*), ao passo que nos *Data Lakes* os dados são armazenados em seu formato bruto e selecionados e organizados de acordo com a necessidade.

A seguir, veja uma imagem ilustrativa.

Data Warehouse

vs.

Data Lake



Com o **Data Warehouse**, os dados são limpos e organizados em um único esquema antes do armazenamento.

A análise é realizada por meio de consulta direta no *Data Warehouse*.



Com o **Data Lake**, os dados são armazenados em seu formato bruto.

Os dados são selecionados e organizados de acordo com a necessidade.

<https://pucrio.grupoa.education/plataforma/course/2799406/content/55351104>

10/18

Tipos de problemas

Até aqui, você pôde entender que a ciência de dados pode englobar análises **descritivas**, **diagnósticas**, **preditivas** ou **prescritivas**. Para as análises descritivas e diagnósticas, geralmente utilizamos técnicas de *Business Intelligence*, ao passo que, para a análise preditiva, podemos utilizar técnicas de *Machine Learning*.



Assim como para o processo de KDD, especificamente **em *Machine Learning*, o aprendizado por meio dos dados é o objetivo principal**. Aprendizado é a capacidade de se adaptar, modificar e melhorar seu comportamento e suas respostas. É uma das propriedades mais importantes dos seres inteligentes (humanos ou não).

Os problemas de *Machine Learning* podem ser agrupados de acordo com suas características. Os principais grandes tipos de aprendizado são o supervisionado e o não supervisionado.

Aprendizado supervisionado

No **aprendizado supervisionado**, o modelo é construído a partir dos dados de entrada (também chamados de *dataset*), que são apresentados para um algoritmo na forma de pares ordenados (entrada – saída desejada). Dizemos que esses dados são rotulados, pois sabemos de antemão a saída esperada para cada entrada de dados. Nesse caso, o aprendizado (ou treinamento) consiste em apresentarmos para o algoritmo um número suficiente de exemplos (também chamados de registros ou instâncias) de entradas e saídas desejadas (já rotuladas previamente). Assim, o objetivo do algoritmo é aprender uma regra geral que mapeie as entradas nas saídas

corretamente, o que consiste no modelo final.


Os dados de entrada podem ser divididos em dois grupos:

- **X**, com os atributos (também chamados de características) a serem utilizados na determinação da classe de saída (também chamados de atributos previsores ou de predição);
- **Y**, com o atributo para o qual se deseja fazer a predição do valor de saída categórico ou numérico (também chamado de atributo-alvo ou *target*).

Fique ligado!

É comum que particionamos os dados de entrada (rotulados) em dois conjuntos: o **conjunto de treinamento**, que servirá para construir o modelo, e o **conjunto de teste** (também chamado, na literatura, de conjunto de validação), que servirá para verificar como o modelo se comportaria em dados não vistos, de forma que possamos ajustá-lo, se necessário, para a construção final do modelo, a ser aplicado em novos dados dos quais ainda não conhecemos a saída esperada.

A figura a seguir ilustra o funcionamento desse tipo aprendizado.



As principais categorias de problemas de aprendizado supervisionado são **classificação** e **regressão**. Observe, no Infográfico a seguir, um exemplo de problema de classificação.

Exemplificando classificação

Um exemplo do **problema de classificação** é a **detecção de clientes com perfis fraudulentos**.

Imagine que um cliente deseja obter um empréstimo de R\$ 1.000,00.
O gestor desse sistema poderia se perguntar:


1. "Será que esse cliente vai pagar o empréstimo?"
2. "Qual é o melhor modelo de financiamento para esse cliente (juros, prazo, etc.)?"



Observe



Este é um **problema típico de classificação**, pois deseja-se classificar um cliente em uma das possíveis classes do problema: por exemplo, bom pagador/mau pagador ou juros/prazo/outros.




Já o problema de **regressão** é parecido com o de classificação, com a diferença de que, em vez de o objetivo ser determinar uma classe, tenta-se prever um valor estimado. Confira um exemplo:

Exemplificando regressão


Para exemplificar um problema de regressão, podemos usar a predição do valor estimado das vendas em uma nova filial de determinada cadeia de lojas. Se essa pergunta for mapeada em um **problema de classificação**, as respostas possíveis **poderiam ser: alto/médio/baixo**.

Se mapeada em um **problema de regressão**, as respostas **poderiam ser valores monetários**.




Aprendizado não supervisionado

Já no **aprendizado não supervisionado**, não existe a informação dos rótulos históricos, ou seja, não temos as saídas desejadas a serem estimadas. Por esse motivo, dizemos que nossos dados são não rotulados. Assim, o algoritmo não recebe durante o treinamento os resultados esperados, devendo descobrir por si só, por meio da exploração dos dados, os possíveis relacionamentos entre eles. Nesse caso, o processo de aprendizado busca identificar regularidades entre os dados a fim de agrupá-los ou organizá-los em função das similaridades que apresentam entre si. Como não temos dados rotulados, não há necessidade de realizar particionamento em conjuntos de treino e teste. A figura a seguir ilustra o funcionamento do aprendizado não supervisionado.



São exemplos de problemas de aprendizado não supervisionado a **clusterização (ou agrupamento)** e a **associação**.

O problema de **clusterização** tem o objetivo de agrupar os dados de interesse. Acompanhe o exemplo a seguir.



Agora, veja um exemplo de problema de **associação**.

Exemplificando associação

O problema de **associação** pode ser exemplificado pela oferta de novos serviços e produtos para clientes.
Por exemplo, em um sistema de e-commerce, poderíamos nos perguntar:

1. "QUEM OBSERVA ESSE PRODUTO


Observe o esquema. Clique nos

Interativo

Descrição do interativo

2. "QUEM OBSERVA ESSE PRODUTO TEM INTERESSE EM VER QUAL OUTRO?"

Observe a imagem.



ASSOCIAÇÃO
Sistema de e-commerce

↓

Exemplo:
Oferta de novos serviços
e produtos para clientes

De forma análoga ao que observamos quando falamos de KDD, apesar de a essência principal de *Machine Learning* consistir na construção de algoritmos de aprendizado supervisionado ou não supervisionado, esta não é a única etapa em que devemos nos concentrar.

É muito importante que entendamos bem o problema a ser resolvido para que possamos traçar os objetivos principais. Em seguida, será necessário coletar e analisar os dados adequados para o problema e prepará-los, pois, na maioria das vezes, eles virão com informações faltantes, incompletas ou inconsistentes. Após essas etapas é que podemos construir o modelo de *Machine Learning*, que deve ser avaliado e criticado, e, se necessário, voltar à etapa de coleta e análise de dados, para a obtenção de mais dados, ou mesmo retornar à etapa de construção do modelo, usando diferentes estratégias. Quando se chegar a um modelo satisfatório para o problema, será necessário apresentar os resultados para o demandante (cliente) e distribuir o modelo em ambiente produtivo, sem esquecer de monitorá-lo periodicamente para verificar se continua com bom desempenho e gerando bons resultados.


Tipos de problemas de ciência de dados e 7 etapas de um projeto de ciência de dados

Neste vídeo, você vai ver os conhecimentos que um bom cientista de dados precisa ter. Reforcaremos os conceitos de aprendizado supervisionado e não supervisionado. Além disso, você vai conhecer o esquema básico de um projeto de ciencias de dados. De o play e aproveite o conteúdo!



Esquema básico de um projeto de ciência de dados

A figura a seguir ilustra o esquema básico de um projeto de ciência de dados, que pode ser resumido em 7 etapas.




Agora, entenda os detalhes de cada uma das etapas.

1. Definição do problema

2. Coleta e análise de dados
3. Pré-processamento
4. Modelagem e interferência
5. Pós-processamento
6. Apresentação dos resultados
7. Implantação do modelo e geração de valor

É importante ressaltar que, por mais que se fale em ciência de dados em temas como *Machine Learning* e inteligência artificial, o papel do ser humano é fundamental na formulação dos objetivos, na escolha de técnicas de pré-processamento de dados e algoritmos utilizados e na parametrização dos algoritmos para a construção dos modelos. Você sempre deve usar a sua experiência, conhecimento e intuição para tomar as melhores decisões, bem como o método científico, a fim de garantir a confiabilidade dos resultados obtidos.



No vídeo a seguir, você vai ver a importância de enxergar os dados como ativos nas empresas e de utilizá-los para a tomada de decisão. Confira.

React de mercado

Este vídeo conta com a participação do convidado Anhur Barbosa, coordenador de dados e analytics na Petrobras e analista de sistemas formado pela UFRJ, com mais de 10 anos de experiência profissional na área de dados e com diversos projetos entregues para a empresa.



Assista o vídeo

Vamos pensar um pouco sobre isso?

Reflita

Em sua experiência profissional, as organizações enxergam os seus dados como ativos e os utilizam adequadamente para a tomada de decisão, ou seja, são empresas *Data Driven*?

Referências

Clique aqui para acessar as referências e créditos desta aula.

