


MATERIAL DE APOIO

Análise exploratória com estatística descritiva

Organiza e descreve os dados usando tabelas e gráficos. Pode ser dividida em dois grupos:



- **Medidas de posição/medidas de tendência central:** permitem saber a posição de concentração dos dados.
 - Exemplos: média, moda, mediana e medidas separatrizes.
- **Medidas de dispersão:** permitem saber o grau de dispersão dos dados em torno de uma medida de posição, geralmente a média dos dados.
 - Exemplos: desvio padrão, variância e coeficiente de variação.

Medidas de tendência central (ou de posição)

- Possibilitam saber o grau de **concentração** dos dados.
- São uma forma de resumir os seus dados por meio de valores representativos do conjunto de dados.

São exemplos de medidas de tendência central: **média**, **mediana**, **moda** e **medidas separatrizes**.

Média

É considerada uma medida **volátil**, uma vez que é afetada/sensível por/a valores extremos/atípicos (*outliers*).

Propriedades:

- Ao se somar ou subtrair uma constante a todas as observações do conjunto, ela fica somada ou subtraída do valor da constante.
- Ao se efetuar a multiplicação ou divisão por uma constante a todas as observações, ela fica multiplicada ou dividida pela mesma constante.

Apesar de ser fácil de computar, nem sempre é a melhor medida: quando há alta variabilidade nos dados, medidas mais robustas (como a mediana e a moda) podem ser mais úteis.

Média aritmética (MA)

É a soma de todos os elementos do conjunto, dividida pelo número de elementos que compõem o conjunto.

$$\bar{x} = \frac{x_1 + x_2 + x_3 \dots + x_n}{n} = \frac{\sum_i^n x_i}{n}$$

Média ponderada (W)

Calculada por meio do somatório das multiplicações entre valores (x) e pesos divididos pelo somatório dos pesos (w).

$$W = \frac{\sum_i^n w_i x_i}{\sum_i^n w_i}$$

Média geométrica (MG)

É a raiz n-ésima do produto de todos os elementos que compõem o conjunto.

$$MG = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}$$

Mediana

É o valor da variável que divide os dados ordenados em duas partes de igual frequência.

É considerada uma medida robusta, uma vez que não é afetada por valores extremos (*outliers*).

Propriedades:

- Ao se somar ou subtrair uma constante a todas as observações do conjunto, ela fica somada ou subtraída do valor da constante.
- Ao se efetuar a multiplicação ou divisão por uma constante a todas as observações, ela fica multiplicada ou dividida pela mesma constante.

Cálculo da mediana

- Colocar os dados em rol (ordenar os dados de forma crescente ou decrescente).
- Observar a paridade do n , pois o cálculo da mediana difere para n para e n ímpar:
 - Se n é ímpar, temos uma posição central única, dada por PC (posição central) = $(n+1)/2$. Após calcularmos a PC, a mediana será o valor que ocupa a posição central.
 - Se n é par, calcularemos duas posições centrais, PC1 (posição central 1) = $n/2$ e PC2 (posição central 2) = $(n/2) + 1$. Após calcularmos PC1 e PC2, a mediana será a média aritmética de PC1 e PC2.

Exemplo: calcule a mediana das observações: {7,1,5,2,3,1,6}.

- Ordenar os dados: {1,1,2,3,5,6,7}.
- Calcular PC: como $n = 7$ (ímpar), temos somente uma PC: $PC = (n+1)/2 \therefore PC = (7+1)/2 = 4$.

- Concluimos que a mediana é a observação cuja posição, com os dados ordenados (em rol), é a quarta. Logo, $Md = 3$.

Moda

É o valor que tem a maior frequência simples no conjunto de dados, consequentemente o de maior probabilidade de ocorrência em um conjunto de dados não agrupados em classes.

É considerada uma medida robusta, uma vez que não é afetada por valores extremos.

Propriedades:

- Ao se somar ou subtrair uma constante a todas as observações do conjunto, ela fica somada ou subtraída do valor da constante.
- Ao se efetuar a multiplicação ou divisão por uma constante a todas as observações, ela fica multiplicada ou dividida pela mesma constante.

Cálculo da moda

Exemplo 1: calcule a moda do conjunto {4,5,4,6,5,8,4}.

Vamos construir a tabela de frequências para facilitar a nossa visualização:

X	f_i
4	3
5	2
6	1
8	1

A moda é 4, pois tem a maior frequência simples do conjunto; logo, a moda é única e chamada de **unimodal**.

Exemplo 2: calcule a moda do conjunto {4,5,4,6,5,8,4,4,5,5}.

Vamos construir a tabela de frequências para facilitar a nossa visualização:

X	f_i
4	4
5	4
6	1
8	1

A moda tem dois valores, pois duas observações do conjunto se repetem quatro vezes. Portanto, a moda é 4 e 5 e é chamada de **bimodal**.

Exemplo 3: calcule a moda do conjunto {1,2,3,4,5}.

Vamos construir a tabela de frequências para facilitar a nossa visualização:

X	f _i
1	1
2	1
3	1
4	1
5	1

A moda não tem valor, pois nenhuma observação do conjunto se repete mais de uma vez; portanto, é chamada de **amodal**.

Medidas separatrizes

Dividem o conjunto de dados em n partes iguais. As mais utilizadas são os **quartis** e os **percentis**.


Quartis: dividem o conjunto em quatro partes iguais.

1. **Primeiro quartil (Q1):** é o valor que deixa o conjunto de dados 25% abaixo dele e 75% para cima.
2. **Segundo quartil (Q2 = mediana):** é o valor que deixa o conjunto de dados 50% abaixo dele e 50% para cima, em duas partes de igual frequência.
3. **Terceiro quartil (Q3):** é o valor que deixa o conjunto de dados 75% abaixo dele e 25% para cima.

Primeiro quartil (Q1)	Segundo quartil (Q2)		Terceiro quartil (Q3)
25%	25%	25%	25%

Medidas de assimetria

Possibilitam analisar uma distribuição em relação a sua moda, mediana e média.



Medidas de dispersão ou medidas de variação

- Permitem saber o grau de dispersão dos dados em relação a uma medida de tendência central (geralmente a média).
- Medem se os dados estão compactados ou espalhados.

São exemplos de medidas de dispersão: **amplitude**, **variância**, **desvio padrão**, **coeficiente de variação**.

Vamos entender cada conceito **associado a população e amostra**.

▪ POPULAÇÃO

Amplitude populacional: diferença entre o maior e o menor valor da população.

$$H = (\text{máximo} - \text{mínimo})$$

Variância populacional: valor médio dos quadrados dos desvios de cada valor da população em relação ao valor médio da população.

$$\sigma^2 = \frac{(x_1 - \bar{x}) + (x_2 - \bar{x})^2 + \dots + (x_N - \bar{x})^2}{N} = \frac{\sum_i^N = j(x_i - \bar{x})^2}{N}$$

Desvio padrão populacional: raiz quadrada da variância populacional.

$$\sigma = \sqrt{\sigma^2}$$

Obs.: Mais fácil de interpretar por estar na mesma escala que os dados originais.

Coeficiente de variação populacional: razão entre o desvio padrão populacional e a média populacional. É um indicador de homogeneidade dos dados da população.

$$CV_x = \frac{\sigma}{\mu'}$$

Obs.: Adimensional. Em geral, consideramos um coeficiente de variação < 25% um bom indicador de homogeneidade dos dados.

▪ AMOSTRA

Amplitude amostral: diferença entre o maior e o menor valor da amostra.

$$h = (\text{máximo} - \text{mínimo})$$

Variância amostral: valor médio dos quadrados dos desvios de cada valor da amostra em relação ao valor médio da amostra.

$$s^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n - 1} = \frac{\sum_i^n (x_i - \bar{x})^2}{n - 1}$$

Desvio padrão amostral: raiz quadrada da variância amostral.

$$s = \sqrt{s^2}$$

Coefficiente de variação amostral: razão entre o desvio padrão populacional e a média populacional. É um indicador de homogeneidade dos dados da amostra.

$$CV_x = \frac{s}{\bar{x}}$$

