



AULA 2

Análise exploratória de dados



Objetivos de aprendizagem

Ao final desta aula, você irá:

- Compreender a etapa de análise exploratória de dados no contexto de projetos de ciência de dados e entender sua importância.
- Entender conceitos básicos da estatística descritiva utilizados em ciência de dados.
- Reconhecer e construir gráficos utilizados na etapa de análise exploratória de dados.
- Conhecer as principais bibliotecas Python utilizadas para análise exploratória de dados e entender na prática como se faz uma análise exploratória de dados.




Nesta segunda aula, o foco será a etapa de análise exploratória de dados, compreendendo sua importância no contexto de projetos de ciência de dados. Também exploraremos alguns conceitos básicos da estatística descritiva utilizados em ciência de dados e veremos exemplos de gráficos utilizados na etapa de análise exploratória de dados. Em seguida, iremos para a parte prática da aula: falaremos sobre as principais bibliotecas Python utilizadas e faremos uma análise exploratória de dados prática.

Que história é essa?

Análise exploratória de dados

Para começar, vamos relembrar o **esquema básico de um projeto de ciência de dados**, apresentado na aula anterior. Nosso foco, agora, será a etapa de **coleta e análise de dados**, como ilustra a figura a seguir:



Esta **etapa de coleta e análise de dados inclui a análise exploratória de dados**. Trata-se de uma etapa crítica, porque é muito importante que você, primeiro, compreenda bem os seus dados para depois explorar as possíveis soluções.

Fique ligado!

Após entendê-los, você poderá limpar, transformar e apresentar melhor os seus dados, bem como obter os melhores resultados possíveis nos algoritmos de *Machine Learning*. Para tal, além de utilizar conceitos da estatística descritiva, podemos utilizar técnicas de visualização de dados (gráficos), o que ajuda a entender melhor seus dados e identificar valores discrepantes, faltantes ou inválidos, verificar a necessidade de alguma transformação de dados, identificar atributos redundantes, etc.

Estatística descritiva



A close-up photograph showing a person's hand holding a yellow-topped blood test tube filled with red liquid. The test tube has a white label with the word "ANEMIA" printed in bold black capital letters. The hand is positioned over a medical chart or form. The chart has two main columns: "HEMATOLOGY" on the left and "OTHER ANALYSES" on the right. Under "HEMATOLOGY", there are several rows with checkboxes and labels: Anemia, Adenopathy, Anticoagulant Heparin, Anticoagulant Sintrom, Bleeding diathesis, Coagulopathy, Erythrocytosis, Ferritin, Gamma globulin, Hemoglobin, Hematocrit, Splenomegaly, Thrombocytopenia. Under "OTHER ANALYSES", there are checkboxes for Progesterone, Bile acids, and Cardiolipin. A small logo is visible in the bottom right corner of the image.

Isso não é viável. Por isso, é preciso coletar uma amostra.

4/22



Estatística descritiva – medidas de posição e de dispersão


Neste vídeo, falaremos sobre os conceitos básicos da estatística descritiva.



Para conferir tudo o que foi visto no vídeo, acesse o material de apoio:

[Clique aqui](#) para baixar.

Os dados brutos são dados na sua forma mais primitiva, desprovidos de ordenação, assim que coletados, e rol estatístico são os dados brutos já ordenados, em ordem crescente ou decrescente. Para analisar dados, muitas vezes os organizamos em tabelas (dados tabulados), e podemos expressá-los em tabelas de frequência. As figuras a seguir exemplificam esses conceitos:



Interativo

Interativo que, em seu primeiro slide, apresenta duas tabelas. A primeira, em uma caixa vermelha, apresenta o título: Frequência absoluta simples. É a contagem simples de elementos. A tabela apresenta os seguintes dados: Idade (anos): 10. f_i : 4. Idade: 30. f_i : 8. Idade: 50. f_i : 4. Idade: 70. f_i : 3. Idade: 90. f_i : 1. A segunda tabela apresenta, em uma caixa vermelha: Frequência relativa simples. É a contagem simples de elementos, dividida pela soma das frequências simples, representando a proporção ou o percentual de observações. A tabela apresenta os seguintes dados: Idade (anos): 10. Fr: 4 sobre 20 = 0 virgula 2 ou 20%. Idade: 30. Fr: 8 sobre 20 = 0 virgula 4 ou 40%. Idade: 50. Fr: 4 sobre 20 = 0 virgula 2 ou 20%. Idade: 70. Fr: 3 sobre 20 = 0 virgula 15 ou 15%. Idade: 90. Fr: 1 sobre 20 = 0 virgula 05 ou 5%. No segundo slide, vê-se a terceira tabela, que apresenta, em uma caixa azul, o título: Frequência absoluta acumulada: É a contagem acumulada até a classe de interesse. A tabela apresenta os seguintes dados: Idade (anos): 10. Fac: 4. Idade: 30. Fac: $(8+f_1) = 12$. Idade: 50. Fac: $(4+f_1+f_2) = 16$. Idade: 70. Fac: $(3+f_1+f_2+f_3) = 19$. Idade: 90. Fac: $(1+f_1+f_2+f_3+f_4) = 20$. A quarta tabela apresenta, em uma caixa azul: Frequência relativa acumulada: É a contagem acumulada até a classe de interesse, dividida pela soma das frequências simples. A tabela apresenta os seguintes dados: Idade (anos): 10. Frac: 4 sobre 20 = 0 virgula 2 ou 20%. Idade: 30. Frac: 12 sobre 20 = 0 virgula 6 ou 60%. Idade: 50. Frac: 16 sobre 20 = 0 virgula 8 ou 80%. Idade: 70. Frac: 19 sobre 20 = 0 virgula 95 ou 95%. Idade: 90. Frac: 20 sobre 20 = 1 ou 100%.

Em estatística, as variáveis são características associada a uma população, podendo ser classificadas em:




Interativo

Interativo com o título: Qualitativas. Abaixo, lê-se o texto: Representam atributos ou qualidades, sendo: ORDINAIS quando existir uma ordem implícita, como classe social, grau de instrução e estágio da doença. NOMINAIS quando não existir uma ordem implícita, como sexo, cor dos olhos, fumante/não fumante e doente/sadio. No segundo slide, lê-se o título: Quantitativas. Abaixo, lê-se o texto: Representam quantidades, sendo: DISCRETAS quando for finita e enumerável, como números de filhos, números de carros e número de cigarros fumados por dia. CONTÍNUAS quando os resultados possíveis pertencerem a um intervalo de números reais e resultados de mensuração, como peso, altura e salário.


Gráficos para visualização de dados

Quando queremos observar o comportamento de determinadas variáveis de forma rápida e sintetizada, especialmente quando têm um número elevado de observações, pode ser uma excelente ideia utilizar gráficos. Contudo, existem gráficos apropriados para cada tipo de variável. Para **variáveis qualitativas**, podemos destacar:






Para as **variáveis quantitativas**, teremos uma variedade maior de gráficos. No caso de variáveis quantitativas **discretas**, geralmente organizamos os dados em tabelas de frequência, e a representação gráfica é mediante gráfico de barras, similar ao visto para as variáveis qualitativas. A representação gráfica também pode ser feita em um **gráfico de dispersão** (*scatter plot*), um gráfico similar ao de barras, porém são plotadas somente as intersecções dos pontos de x e y, como ilustram as figuras a seguir:



Já para as variáveis quantitativas contínuas, podemos usar o **histograma**, um gráfico de barras contíguas, com as bases proporcionais aos intervalos de classe e a área do retângulo proporcional à respectiva frequência, ou o **gráfico de linhas**, utilizado quando estamos interessados em expressar variáveis que representam passagem de tempo, ou seja, mostrar a evolução histórica. Observe nas figuras a seguir:



Para trabalharmos com as medidas de tendência central e de dispersão graficamente, podemos usar o **diagrama de caixas** (**boxplot**), que é uma representação gráfica da distribuição dos dados. Esse diagrama nos dá informação da assimetria da distribuição, da presença de *outliers* (valores atípicos) e da variabilidade dos dados por meio da amplitude (máx-min). No *boxplot*, dentro do quadrado (*box*), encontramos 50% dos dados, delimitados pelo primeiro e terceiro quartis e pela mediana. Fora do quadrado, os delimitadores representados por pequenas linhas retas mostram o limite razoável dos dados, e os pequenos círculos fora desses delimitadores representam possíveis *outliers*. Acompanhe no Infográfico:



Boxplot

A figura a seguir ilustra um *boxplot*:

Diagram illustrating the components of a boxplot:

- Máximo (Maximum)
- Whisker
- Q3
- Q2 = Mediana (Median)
- Q1
- Whisker
- Mínimo (Minimum)
- Possíveis outliers (Possible outliers)

Os *boxplots* também podem ser utilizados para comparar visualmente as distribuições de uma variável numérica agrupada conforme uma variável categórica, como ilustra a figura abaixo:

Boxplots comparativos.


Fonte: Bruce e Bruce (2019).

A análise exploratória de dados muitas vezes envolve o estudo da **correlação** entre preditores e entre preditores e uma variável-alvo. Dizemos que as variáveis *x* e *y* têm correlação positiva se *x* aumenta quando *y* aumenta e correlação negativa se quando *x* aumenta, *y* diminui (e vice-versa). O **coeficiente de correlação** mede o nível em que as variáveis numéricas estão associadas umas às outras e varia de -1 a $+1$, em que 0 significa ausência de correlação. Vale a pena ressaltar que o coeficiente de correlação é sensível a *outliers* nos dados. A **matriz de correlação** é uma tabela na qual as variáveis são mostradas tanto nas linhas quanto nas colunas, os valores das células são a correlação entre as variáveis, e o gráfico de correlação é a sua representação gráfica, como ilustra a figura a seguir:



Matriz e gráfico de correlação

	T	CTL	FTR	VZ	LVL
T	1.000	0.475	0.328	0.678	0.279
CTL	0.475	1.000	0.420	0.417	0.287
FTR	0.328	0.420	1.000	0.287	0.260
VZ	0.678	0.417	0.287	1.000	0.242
LVL	0.279	0.287	0.260	1.242	1.000



Fonte: Adaptado de Bruce e Bruce (2019).

Bibliotecas Python para análise exploratória

Conheça as bibliotecas *Python* para análise exploratória.

NumPy



Pandas



Matplotlib



Seaborn



Exemplo de análise exploratória em Python com o *dataset* iris

Para exemplificar como funciona a etapa de análise exploratória de dados em um *dataset*, iremos utilizar o pacote **Pandas**, focando em algumas possibilidades interessantes de análises, mas sem nenhuma pretensão de ser um tutorial exaustivo desse pacote, que é muito amplo e rico.

Aprenda mais!

10 minutes to pandas

Para conhecer mais o Pandas, você pode explorar um dos diversos tutoriais oficiais.

[Clique aqui](#) e acesse



Observação: como as bibliotecas Python são dinâmicas e evoluem ao longo do tempo, este exemplo pode conter trechos de código desatualizados. O código fonte original, disponível no GitHub da disciplina, estará sempre atualizado.

Iniciaremos esta prática importando o Pandas:


```
cod.py
1 # importação do Pandas
2 import pandas as pd
```

Agora, iremos importar o dataset a partir de um *link* e armazenar os dados em um *dataframe*.

Nesta prática, trabalharemos com o *dataset iris*, um dos *datasets* mais conhecidos e utilizados em *Machine Learning*, criado em 1936. Este é um *dataset* pequeno e simples, ideal para uma primeira prática, e contém 150 instâncias (linhas), 4 variáveis numéricas (largura e comprimento da sépala e da pétala em centímetros) e 1 variável categórica (espécie da flor, podendo ser *setosa*, *versicolor* ou *virginica*).

```
cod.py
1 # importando dados uma url para um dataframe
2
3 # url a importar
4 url_dados = 'https://archive.ics.uci.edu/ml/machine-learning-databases/iris/iris.data'
5
6 # labels dos atributos do dataset
7 labels_atributos = ['comprimento_sepala', 'largura_sepala', 'comprimento_petala',
8                    'largura_petala', 'especie']
9
10 # carga do dataset através da url - há diversos parâmetros no read_csv que podem
11 # ser interessantes, como sep, usecols e header
12 iris = pd.read_csv(url_dados, names=labels_atributos)
```


Acompanhe a sequência.




Interativo

Interativo em que, no primeiro slide, lê-se: Inicialmente, iremos utilizar alguns comandos da biblioteca Pandas para exibir algumas estatísticas descritivas e fazer uma rápida análise exploratória do dataset. Os comentários nos blocos de código auxiliam no seu entendimento. No segundo slide, vemos o seguinte código: Linha 1 cerquilha verificando que iris é um dataframe Linha 2 type abre parênteses iris fecha parênteses. Abaixo, vê-se o seguinte resultado: pandas ponto core ponto frame ponto DataFrame. Abaixo, vê-se o seguinte código: Linha 1 cerquilha exibindo as primeiras linhas Linha 2 iris ponto head abre parênteses fecha parênteses. Abaixo, vê-se uma tabela, que apresenta os dados comprimento underline sepala, largura underline sepala, comprimento underline petala e largura underline petala para a espécie Iris traço setosa. No terceiro slide, vemos o seguinte código: Linha 1 cerquilha exibindo as últimas linhas Linha 2 iris ponto tail abre parênteses fecha parênteses. Abaixo, vê-se uma tabela, que apresenta os dados comprimento underline sepala, largura underline sepala, comprimento underline petala e largura underline petala para a espécie Iris traço virgínica. No slide 4, vemos o código Linha 1 cerquilha exibindo os nomes das colunas Linha 2 iris ponto columns. Abaixo, vê-se o resultado: Index abre parênteses abre colchetes apóstrofo comprimento underline sepala apóstrofo vírgula apóstrofo largura underline sepala apóstrofo vírgula apóstrofo comprimento underline petala apóstrofo vírgula, na linha abaixo, recuo apóstrofo largura underline petala apóstrofo vírgula apóstrofo especie apóstrofo fecha colchetes vírgula, na linha abaixo, recuo dtype igual a apóstrofo object apóstrofo fecha parênteses. Abaixo, vê-se o código Linha 1 cerquilha exibindo as dimensões do dataset Linha 2 iris ponto shape. Abaixo, tem-se o resultado: abre parênteses 150 vírgula 5 fecha parênteses. A seguir, vê-se o código Linha 1 cerquilha exibindo a quantidade de linhas por coluna Linha 2 iris ponto count abre parênteses fecha parênteses. Abaixo, vê-se uma tabela com, na esquerda, os dados comprimento underline sepala, largura underline sepala, comprimento underline petala, largura underline petala, e especie com o valor de 150 à direita. Abaixo desses, também se apresenta o dado dtype dois pontos int64. No slide 5, vê-se o código Linha 1 cerquilha exibindo um sumário estatístico Linha 2 iris ponto describe abre parênteses fecha parênteses. Abaixo dele, vê-se uma tabela, apresentando na primeira linha os dados comprimento underline sepala, largura underline sepala, comprimento underline petala, largura underline petala, e na primeira coluna, os dados count, mean, std, min, 25 por cento, 50 por cento, 75 por cento e max. Os números de cada uma das células interiores são apresentados.

A fim de analisarmos os nossos dados de diversos ângulos, o Pandas permite reorganizarmos um *dataframe*, por exemplo, ordenando-o por alguma coluna.






Interativo

Interativo em que, no primeiro slide, lê-se: Também podemos selecionar uma ou mais colunas e/ou linhas específicas, como mostram os exemplos a seguir. Os comentários nos blocos de código auxiliam no seu entendimento. No slide 2, vê-se o código: Linha 1 cerquilha ordenando o dataframe por uma coluna Linha 2 iris ponto sort underline values abre parênteses by igual a apóstrofo largura underline sepala apóstrofo fecha parênteses Linha 3 vazia Linha 4 cerquilha obs dois pontos este comando retorna apenas o resultado da query ponto Se quisermos alterar Linha 5 cerquilha a ordenação do dataframe em si vírgula teríamos que fazer dois pontos Linha 6 cerquilha iris igual a iris ponto sort underline values abre parênteses by igual a apóstrofo largura underline sepala apóstrofo fecha parênteses. Abaixo, vê-se uma tabela apresentando os dados comprimento underline sepala, largura underline sepala, comprimento underline petala e largura underline petala para as espécies Iris traço versicolor, iris traço virginica e iris traço setosa, em ordem crescente pela coluna largura underline sepala. No slide 3, vê-se o código: Linha 1 cerquilha ordenando por uma coluna de ordem descendente Linha 2 iris ponto sort underline values abre parênteses by igual a apóstrofo largura underline sepala apóstrofo vírgula ascending igual a False fecha parênteses. Abaixo, vê-se a mesma tabela do slide anterior, dessa vez organizada em ordem decrescente pela coluna largura underline sepala. No slide 4, vê-se o código Linha 1 cerquilha selecionando uma coluna específica Linha 2 iris abre colchetes apóstrofo largura underline sepala apóstrofo fecha colchetes. Abaixo, vê-se uma tabela que apresenta duas colunas: à esquerda, lista de 0 a 4 e, depois, de 145 a 149. A coluna da direita mostra dados como 3 ponto 5, 3 ponto 0, etc. Abaixo, lê-se name dois pontos largura underline sepala vírgula length dois pontos 150 vírgula dtype dois pontos float64. Abaixo, vê-se o código Linha 1 cerquilha selecionando um subconjunto de linhas consecutivas Linha 2 iris abre colchetes 7 dois pontos 11 fecha colchetes. Abaixo, vê-se como resultado uma tabela que exhibe os dados de comprimento underline sepala, largura underline sepala, comprimento underline petala e largura underline petala para a espécie Iris traço setosa. No slide 5, vê-se o código Linha 1 cerquilha selecionando um subconjunto de colunas para todas as linhas Linha 2 iris ponto loc abre colchetes dois pontos vírgula abre colchetes apóstrofo largura underline sepala apóstrofo vírgula apóstrofo largura underline petala apóstrofo vírgula apóstrofo especie apóstrofo fecha colchetes fecha colchetes. Abaixo, vê-se uma tabela com os dados de largura underline sepala e largura underline petala para as espécies Iris traço setosa e Iris traço virginica. Abaixo, vê-se o código Linha 1 cerquilha selecionando um subconjunto linhas e colunas Linha 2 iris ponto loc abre colchetes 7 dois pontos 11 vírgula abre colchetes apóstrofo largura underline sepala apóstrofo vírgula apóstrofo largura underline petala apóstrofo vírgula apóstrofo especie apóstrofo fecha colchetes fecha colchetes. Abaixo, vê-se o resultado, uma tabela com os dados de largura underline sepala e largura underline petala para a espécie Iris traço setosa. No slide 6, vê-se o código Linha 1 cerquilha selecionando linhas segundo um critério Linha 2 iris abre colchetes iris abre colchetes apóstrofo largura underline sepala apóstrofo fecha colchetes sinal maior que 3 ponto 5 fecha colchetes. Abaixo, vê-se uma tabela com dados de comprimento underline sepala, largura underline sepala, comprimeito underline petala e largura underline petala para as espécies Iris traço setosa e Iris traço virginica. No slide 7, vê-se o código Linha 1




cerquilha exibindo a média de cada atributo vírgula agrupado por espécie Linha 2 iris ponto groupby abre parênteses apóstrofo especie apóstrofo fecha parênteses ponto mean abre parênteses fecha parênteses. Abaixo, vê-se os dados de comprimento underline sepala, largura underline sepala, comprimento underline petala e largura underline petala para as espécies Iris traço setosa, Iris traço versicolor e Iris traço virginica.


Agora que já exploramos um pouco os nossos dados com auxílio da estatística descritiva e da biblioteca Pandas, vamos examinar o *dataset* iris graficamente com a biblioteca Matplotlib. O primeiro tipo de gráfico que criaremos será o gráfico conhecido como **scatter plot**, no qual são marcados os pontos de cruzamento entre duas variáveis. Para isso, será necessário importar o módulo *pyplot* do Matplotlib.




Se quisermos, também podemos plotar o mesmo gráfico, mas colorir-lo de acordo com as espécies das flores (*setosa*, *versicolor* ou *virginica*). Para tal, faremos:




Também podemos separar as classes usando diferentes marcadores em vez de usar cores (o que é útil em relatórios impressos em preto e branco). Para tal, basta fazer:





Vamos agora trabalhar com um tipo diferente de gráficos: o **gráfico de linhas** (*line plot*). Esse tipo de gráfico é utilizado geralmente quando estamos interessados em expressar variáveis que representam passagem de tempo, ou seja, mostrar a evolução histórica, o que não é o caso desse *dataset*. Mas imagine que o *dataset* iris esteja representado na ordem em que as amostras foram coletadas ao longo do tempo e que queremos visualizar a variação dos atributos dos exemplos coletados ao longo do tempo. Nesse caso, faríamos:



O **histograma** exibe a distribuição de frequências de uma variável. É possível informarmos como parâmetro (entre muitas outras possibilidades) o número de *bins* (colunas) que queremos exibir. O exemplo de código a seguir cria um histograma para o atributo comprimento da sépala, com 7 *bins*.





Por sua vez, o **gráfico de barras** (*bar plot*) apresenta retângulos (barras), com uma das dimensões proporcional à quantidade a ser representada e a outra arbitrária, mas igual para todas as barras. Os exemplos a seguir ilustram gráficos de barras (o primeiro, com barras verticais, também chamado de gráfico de colunas, e o segundo, com barras horizontais) para um *dataset* simples, que representa a profissão dos respondentes de uma pesquisa fictícia.



Outra visualização interessante para quantidades de uma variável é o **gráfico de pizza** (*pie plot*). Vejamos esse gráfico com os mesmos dados do exemplo anterior:



Para finalizar os exemplos da biblioteca Matplotlib, vamos plotar, em uma única figura, quatro histogramas do *dataset* iris, um para cada atributo:



Aqui, procuramos trazer apenas exemplos simples para facilitar o entendimento dos códigos. Entretanto, praticamente tudo pode ser customizado, desde configurações mais simples, como cores, tamanhos ou exibição de *labels*, até outras personalizações mais avançadas.



Fique ligado!


Recomendamos que você procure essas opções na documentação oficial de acordo com a sua necessidade de uso.

Vamos agora explorar outra biblioteca para gráficos em Python: o pacote **Seaborn**.

Todos os exemplos a seguir também utilizarão o *dataset* iris, que já carregamos previamente. Você notará que os três primeiros exemplos de gráficos com Seaborn produzem o mesmo resultado de alguns gráficos que criamos com Matplotlib. Vamos começar importando a biblioteca:

```
cod.py
1 # importação do Seaborn
2 import seaborn as sns
```

Agora, vamos plotar um *scatter plot* simples, em seguida o mesmo colorido por espécies e um gráfico de linhas com os atributos do *dataset* iris. Clique na seta e repare que é necessário bem menos linhas de código em comparação com o Matplotlib:




Interativo

Interativo apresentando uma imagem que mostra uma tela de código, com o seguinte texto: Linha 1 cerquilha scatter plot com seaborn
Linha 2 sns ponto scatterplot abre parênteses x igual a apóstrofo comprimento underline sepala apóstrofo vírgula y igual a apóstrofo largura underline sepala apóstrofo vírgula data igual a iris fecha parênteses ponto e vírgula. Abaixo, vê-se o resultado, que apresenta um gráfico com pontos azuis sobre um fundo branco. No eixo horizontal, intitulado comprimento sépala, os valores estão marcados de 4 ponto 5 até 8 ponto 0, aumentando em incrementos de 0 ponto 5. No eixo vertical, intitulado largura - sépala, os valores variam de 2 ponto 0 a 4 ponto 5, também em incrementos de 0 ponto 5. Os pontos azuis estão distribuídos ao longo do gráfico, mais concentrados na parte central do eixo horizontal. No slide 2, lê-se o código: Linha 1 cerquilha scatter plot com Seaborn colorido por classes
Linha 2 sns ponto scatterplot abre parênteses x igual a apóstrofo comprimento underline sepala apóstrofo vírgula y igual a apóstrofo largura underline sepala apóstrofo vírgula
Linha 3 recuo hue igual a apóstrofo especie apóstrofo vírgula data igual a iris fecha parênteses ponto e vírgula. Abaixo, no resultado, uma imagem mostra um gráfico com pontos coloridos representando dados sobre um fundo branco. O gráfico possui um eixo horizontal rotulado como comprimento sépala com valores de 4 ponto 5 a 8 ponto 0, e um eixo vertical rotulado como largura sépala com valores de 2 ponto 0 a 4 ponto 5. Os pontos no gráfico são de três cores diferentes: azul, laranja e verde, representando três categorias diferentes, conforme indicado na legenda no canto inferior direito. A legenda especifica que a cor azul representa a espécie Iris-setosa, a cor laranja representa a Iris-versicolor, e a cor verde representa a Iris-virginica. Os pontos azuis estão geralmente posicionados na parte superior esquerdo do gráfico. Os pontos laranja estão mais no centro, e os pontos verdes estão distribuídos mais no centro e à direita do gráfico. No slide 3, vê-se o código
Linha 1 cerquilha gráfico de linhas com Seaborn
Linha 2 sns ponto lineplot abre parênteses data igual a iris ponto drop abre parênteses abre colchetes apóstrofo especie apóstrofo fecha colchetes vírgula axis igual a 1 fecha parênteses ponto e vírgula. Abaixo, vê-se o resultado, um gráfico apresentando quatro linhas tracejadas de cores diferentes representando várias medições ao longo de um eixo horizontal. O eixo horizontal está marcado de 0 a 140 em incrementos de 20. O eixo vertical está marcado de 0 a 8 em incrementos de 1, e é rotulado com valores que variam entre estas marcas. Cada linha no gráfico representa uma variável diferente com cores distintas: azul para comprimento sépala, laranja para largura sépala, verde para comprimento pétala, e vermelho para largura pétala. As linhas variam em altura ao longo do eixo vertical, mostrando diferentes padrões de subida e descida. A linha azul alcança a maior altura no gráfico, a verde em segundo, a laranja em terceiro e a vermelha em último.

Vejamos um exemplo do gráfico *boxplot* com a biblioteca Seaborn, exibindo os boxplots de todos os atributos em um mesmo gráfico:

cod.py


```
1 # boxplot com Seaborn
2 sns.boxplot(data = iris);
```



Agora vamos plotar um histograma do comprimento da sépala:

cod.py


```
1 # histograma com seaborn
2 sns.histplot(iris['comprimento_sepala'], bins=7);
```



Podemos também plotar boxplots simples facilmente:

cod.py


```
1 # boxplot com seaborn
2 sns.boxplot(x=iris['comprimento_sepala']);
```




Um gráfico muito útil para a análise de dados é o **gráfico de correlação**, que exibe graficamente as correlações entre os atributos numéricos de um *dataset*. Com Seaborn, basta uma linha de código para plotá-la. Para fazer algo similar com Matplotlib, são necessárias diversas linhas de código.

cod.py

```
1 # gráfico de correlação com Seaborn
2 sns.heatmap(iris.corr(), annot=True, cmap='RdBu', vmin=-1, vmax=1);
```



Para finalizar, vamos plotar um gráfico composto muito interessante que apresenta, em uma só figura, *scatter plot* de cada par de atributos numéricos do *dataset* e o histograma do atributo na diagonal principal. Se configurarmos o parâmetro *hue*, em vez do histograma, o gráfico exibirá na diagonal principal a distribuição de cada uma das espécies pelo atributo, usando *density plots*. Os dois exemplos são exibidos a seguir. Repare que basta uma única linha de código para que esse gráfico tão interessante seja exibido.



Assim como a Matplotlib, a biblioteca Seaborn é muito extensa, e seus gráficos podem ser personalizados de acordo com sua necessidade. Recomendamos que você explore mais exemplos na documentação oficial de acordo com a sua necessidade de uso.

Vamos ver a análise exploratória de dados na prática?

Análise exploratória de dados na prática com o *dataset* diabetes

Neste vídeo, você verá um código Python com a explicação do passo a passo de cada bloco. Além disso, na Técnica Aplicada, poderá acessá-lo para praticar.



Assista o vídeo

Referências



Clique aqui para acessar as referências e créditos desta aula.

