



AULA 2

Aplicações para visão computacional



Objetivos de aprendizagem da aula

Ao final desta aula, você irá:


- Introduzir os conceitos de transferência de estilo, reconhecimento facial, segmentação de objetos, *deepfakes*, estimativa de pose.
- Reconhecer e compreender os requisitos para *deploy* de aplicações (compressão de redes e dispositivos embarcados).
- Apresentar aplicações reais de visão computacional para indústria.

Que história é essa?

Nesta segunda aula, focaremos em aplicação de redes neurais em visão computacional. Em especial, apresentaremos aplicações envolvendo reconhecimento facial, *tracking* de objetos, *liveness detection*, combate a fraudes em documentos, esteganografia, *deepfakes* e estimativa de pose.

Reconhecimento facial

O reconhecimento facial é uma das subcategorias de aplicações de aprendizado de máquina para segurança e biometria. Em resumo, o processo de reconhecimento facial envolve identificar padrões e conformidades na face indivíduos de acordo com features correspondentes em uma base de dados.



Esses tipos de sistema podem ser aplicados a fotografias, vídeos ou, ainda, a processamento de imagens em tempo real. Muitas pessoas estão familiarizadas com a tecnologia de reconhecimento facial por meio de aplicações comumente usadas para desbloqueio de telefones celulares, por exemplo, como no caso do iPhone.

Normalmente, o reconhecimento facial não depende de um enorme banco de dados de fotos para determinar a identidade de um indivíduo – ele simplesmente identifica e reconhece uma pessoa como a única proprietária do dispositivo.



Além de aplicações inocentes, como desbloquear telefones, o reconhecimento facial pode ser usado por outros sistemas de segurança, que analisam milhares de rostos e fazem uma checagem de informações com uma base de dados.

Muito se tem discutido a respeito das implicações éticas desse tipo de serviço, que pode ser usado por forças de segurança para identificação de pessoas suspeitas de irregularidades. Este ainda é um tópico sensível, visto que um modelo para tal aplicação precisa ser testado e calibrado extensivamente para evitar falsos positivos.

Ainda, tais ferramentas podem ser usadas de forma coercitiva por agências governamentais em muitos países. Portanto, esse tipo de aplicação ainda é um assunto problemático no que diz respeito ao seu uso e ao armazenamento de dados pessoais.

Os sistemas de tecnologia facial podem variar, mas em geral, veja a seguir como tendem a funcionar clicando na flecha ao lado:

Interativo

Interativo com o texto: Detecção de faces: os sistemas devem reconhecer uma região de imagens em que podemos encontrar uma ou mais faces. As imagens podem mostrar as pessoas tanto de frente como de perfil. Normalmente, são usadas redes neurais que detectam pontos-chave nas faces de pessoas e criam uma bounding box sobre a região na imagem. Abaixo, vemos uma imagem que apresenta um grupo de cinco pessoas, duas mulheres e dois homens, todos caucasianos, vestidos em trajes formais como se estivessem em um ambiente corporativo ou de negócios. Cada pessoa tem um retângulo amarelo ao redor do rosto com um ID e uma série de números, que remetem a uma ideia de identificação por reconhecimento facial. O fundo é uma cena urbana em preto e branco com arranha-céus desfocados. No segundo slide, vemos o texto: Análise facial: nesta etapa, basicamente o sistema analisa a geometria associada à face de uma pessoa. Alguns dos elementos-chave podem ser associados à distância entre os olhos, análise das órbitas oculares, tamanho do queixo, bochechas, contorno dos lábios, etc. A identificação dessas características-chave é um dos meios usados para distinguir a face de uma pessoa específica de várias outras em uma base de dados. Abaixo, uma imagem exibe uma mulher olhando para um celular. Seu rosto apresenta com linhas e pontos de mapeamento facial sobrepostos à sua imagem, sugerindo tecnologia de reconhecimento facial. À esquerda, há uma representação gráfica de um cadeado dentro de círculos concêntricos. No terceiro slide, vemos o texto: Converter imagens em dados: o processo de captura de um rosto transforma informações como as fotografias em um conjunto de informações digitais com base nas características faciais apresentadas no slide anterior. Com base na análise facial, um código associado à face é gerado, chamado de faceprint. O faceprint na verdade pode ser visto como um vetor de features faciais. Da mesma forma que as impressões digitais são únicas, cada pessoa tem sua própria ‘impressão facial’. Abaixo, uma imagem também mostra uma mulher com um padrão de mapeamento facial sobreposto ao seu rosto, com ela olhando para um smartphone. Ao redor dela, há gráficos semelhantes a ondas de radar ou sinais de Wi-Fi. No quarto slide, vemos o texto: Matching de características: com o faceprint gerado, este é comparado com milhares de outros previamente computados em uma base dados. O objetivo é identificar pessoas cujas informações estejam associadas a essa base. Abaixo, a imagem é de um homem com um gráfico detalhado de reconhecimento facial cobrindo seu rosto. Ao redor dele, há diversas representações de tecnologia digital, incluindo gráficos de onda, mapas de mundo em rede, e painéis de informação mostrando o processo de Access Permission e Access Granted, aludindo a um sistema de segurança que concede acesso com base no reconhecimento facial.

A seguir, acompanhe algumas aplicações do reconhecimento facial no mundo real.


Aplicações no mundo real

O reconhecimento facial tem muitas aplicações práticas no dia a dia para auxiliar na segurança de acesso aos aplicativos de serviços bancários, no controle de imigração nos aeroportos, no desbloqueio de telefones celulares e em outros serviços, como hospitalares, redes sociais e até serviços de governança.

Veja, a seguir, como funciona cada uma dessas aplicações.

Interativo

Neste interativo, vemos um fundo vermelho com três caixas azuis, cada uma com um título, com a frase abaixo: clique nos cards para saber mais. O texto é o seguinte: Banking (simbolizado por uma imagem gráfica minimalista de notas de dinheiro): Aqui, a ideia é adicionar uma camada de segurança a mais em vez de utilizar a autenticação por apenas senha ou token. Controle de imigração em aeroportos (simbolizado por uma imagem gráfica minimalista de um smartphone que, em sua tela, apresenta a foto de um policial): Um número crescente de passageiros tem documento de passaporte contendo informações biométricas. Isso permite evitar filas e trazer melhorias em relação à segurança. Desbloqueio de telefones celulares (simbolizado por uma imagem gráfica minimalista de um smartphone que, e sua tela, apresenta a foto de uma pessoa): Ainda há uma discussão ética a respeito da privacidade de dados usada por esses dispositivos. Questiona-se se as informações estão disponíveis ou não a empresas que mantêm estes sistemas sem o consentimento dos usuários.



Interativo

Neste interativo, vemos um fundo vermelho com três caixas azuis, cada uma com um título, com a frase abaixo: clique nos cards para saber mais. O texto é o seguinte: Healthcare (simbolizado por uma imagem gráfica minimalista de um smartphone que, em sua tela, apresenta uma cruz): Os hospitais poderão utilizar os sistemas no auxílio ao tratamento de pacientes e na identificação de possíveis doenças. Redes sociais (simbolizado por uma imagem gráfica minimalista de várias pessoas agrupadas): As redes sociais utilizam mecanismos de reconhecimento facial para ‘taggear’ automaticamente as pessoas em fotos. Governança (simbolizado por uma imagem gráfica minimalista de um papel em uma caneta): Alguns sistemas governamentais também utilizam essa técnica para autenticação e verificação de assinaturas digitais, como é o caso do Portal gov.br.

Contudo, esses usos trazem algumas questões éticas, que você pode acompanhar a seguir.

Questões éticas

Antes de falarmos sobre a ética na vigilância, no armazenamento de dados e no falso positivo, é importante saber como funciona o reconhecimento facial ao vivo. Veja no diagrama a seguir.



Com o funcionamento facial ao vivo compreendido, chegou a vez de compreender a aplicação das questões éticas, clique na flecha a seguir para explorar mais o assunto:

Interativo


Interativo com o texto: Vigilância: há um crescente questionamento a respeito de que o uso desses recursos junto às câmeras digitais, praticamente onipresentes, e à inteligência artificial para análise de dados crie um potencial de vigilância de massa, o que poderia dar poder excessivo de monitoramento a agentes do Estado e governos, restringindo liberdades individuais. Abaixo, vê-se a imagem de uma câmera de segurança à esquerda e gráficos de reconhecimento facial ao fundo, com rostos e padrões de mapeamento facial que parecem flutuar em uma interface de usuário, sugerindo monitoramento através de tecnologia avançada. A presença de código binário (0s e 1s) ao fundo contribui para um tema tecnológico. No segundo slide, vemos o texto: Falsos positivos: assim como qualquer outro sistema computacional, algoritmos de reconhecimento facial não são imunes a erros. Se um modelo de reconhecimento facial não for bem calibrado e testado, pode ser usado em julgamentos errôneos, principalmente quando ligado a aplicações de segurança. Abaixo, a imagem mostra uma vista aérea de várias pessoas andando em uma rua ou praça, com algumas delas tendo seus rostos enquadrados e marcados com retângulos azuis. Essas marcações são semelhantes ao reconhecimento facial, com um indivíduo em particular destacado em laranja e rotulado como Not Found. No terceiro slide, vemos o texto: Armazenamento de dados: softwares de reconhecimento facial são hoje, em sua grande maioria, dependentes de modelos de aprendizado de máquina, os quais precisam de grandes volumes de informações para serem treinados. Pequenas empresas podem não ter recursos suficientes para manter tais modelos e podem acabar por depender de fornecedores externos e ficar presas a serviços de consultoria. Abaixo, a imagem exibe mãos digitando em um laptop com ícones de segurança digital e nuvem flutuando acima delas.


Agora, entenda como funciona a arquitetura FaceNet.

FaceNet – uma arquitetura para um sistema de reconhecimento facial

FaceNet é o nome do sistema de reconhecimento facial que foi proposto pelo Google em 2015 no artigo *FaceNet: a unified embedding for face recognition and clustering*. Ainda hoje este é um dos principais sistemas de código aberto cujos resultados ainda estão entre os mais bem avaliados em *datasets* de teste, como Labeled Faces in the Wild (LFW) e Youtube Face Database. Essa arquitetura utiliza um modelo de rede neural convolucional chamada Inception para gerar mapas de *features* faciais.

O modelo dessa arquitetura pode ser visto na figura a seguir:





Esse sistema recebe um *batch* de imagens e, após o processamento pela rede neural, gera um vetor de *features* para os dados de entrada com uma normalização L2 aplicada sobre ele.

Esses *embeddings* são, então, passados posteriormente para a função de *loss*. O objetivo dessa função de perda é fazer com que a distância quadrática entre duas *embeddings* de imagens de uma mesma pessoa seja pequena, enquanto a distância para duas pessoas distintas seja maior.


A função de perda utilizada é chamada de **triplet**, cujo objetivo é ajudar o modelo a impor uma margem de separação entre faces de diferentes pessoas. A função **triplet loss** recebe uma entrada de referência (chamada âncora), e esta é comparada a uma entrada correspondente a dado de entrada (chamada positiva) e uma entrada não correspondente (chamada negativa). A distância da âncora ao dado positivo é minimizada, e a distância da âncora à entrada negativa é maximizada.



Aprenda mais

Clique [aqui](#) para acessar uma implementação da FaceNet.

Que tal assistir a um vídeo para entender melhor como tudo isso funciona?



Desenvolvendo uma aplicação simples para reconhecimento facial com OpenCV, Python e *deep learning*

Este vídeo apresenta um conteúdo fornecido em um *notebook* Python com código. A ideia aqui é desenvolver uma aplicação simples para reconhecimento facial ajustando um modelo de rede neural pré-treinada.

Você pode encontrar o *notebook* utilizado no vídeo, [aqui](#).



Liveness detection

Liveness detection são técnicas usadas para detectar uma tentativa de falsificação, determinando se a fonte de uma amostra biométrica é um ser humano de fato ou uma representação falsa, como, por exemplo, uma *deepfake* ou fotografia.



Existem duas categorias principais para *liveness detection*:

Ativa	↓
Solicita que o usuário execute uma ação que não pode ser facilmente replicada com uma falsificação. Também pode incorporar várias modalidades que não incluem apenas fotografias, mas também dupla autenticação.	
Passiva	↓
Usa algoritmos de <i>machine learning</i> para detectar indicadores de uma imagem sem interação do usuário. A análise de dados biométricos com boa variabilidade e com muitas amostras ajuda no treinamento e na generalização desses modelos.	

Reconhecimento facial e *liveness detection*:

O reconhecimento facial é uma modalidade biométrica ideal para autenticação em diversos sistemas, como em dispositivos móveis. No entanto, a ampla disponibilidade de imagens faciais nas mídias sociais torna a biometria facial mais suscetível à falsificação. Por esse motivo, é fundamental aplicar técnicas de *liveness detection* em sistemas que fazem uso de algoritmos de reconhecimento facial.



Após o processo de reconhecimento facial, e antes da autenticação de fato, uma técnica de aprendizado de máquina é usada para distinguir entre uma imagem real e uma fotografia impressa ou digital do rosto de um usuário. Outras tentativas de falsificação podem envolver o uso de uma máscara e, ainda, *deepfakes*.

As tentativas de falsificação podem ser detectadas por meio de algoritmos de reconhecimento de padrões, que analisam artefatos como variações anormais de pixels na imagem, ou ainda com a ajuda de sensores de profundidade e modelos que conseguem realizar uma análise da geometria 3D da face.

Há trabalhos que propõem métodos de *liveness detection* baseados na estrutura 3D da face.



Mediante o processamento da curvatura 3D dos dados adquiridos com sensores de profundidade (como nos novos iPhones), ou por meio de múltiplas imagens 2D, é possível que um sistema biométrico distinga um rosto real de um ataque de apresentação 2D, nomeadamente na apresentação de uma fotografia.

Com relação ao uso de técnicas de *machine learning* para a prova de vida, algumas dessas técnicas tratam esse desafio como um problema de classificação binário e apresentaram uma abordagem em que extraem as *features* das faces a partir de uma arquitetura de redes de convolução.

Posteriormente, usam um algoritmo SVM para classificar as imagens como falsificação ou apresentação fidedigna. Além disso, implementam uma etapa de pré-processamento das imagens variando os tamanhos das *boundding boxes* das faces e o número de *frames* sucessivos a serem analisados pelas redes neurais convolucionais (CNNs).

Deepfakes

Deepfakes são imagens, vídeos ou áudio gerados artificialmente por computador com o uso de técnicas de *deep learning*, cujo objetivo é, da maneira mais realista possível, fingir ações de uma pessoa real. Por exemplo, a técnica mais comum é identificar a face de uma pessoa em um vídeo e substituí-la por outra digitalmente. Esse tipo de técnica representa um desafio à identificação de ataques a sistemas de biometria, como no exemplo da seção anterior.

Além disso, atualmente muito se tem usado essa técnica como um meio de disseminar desinformação pela internet, o que representa também um desafio às agências de checagem de informação.



Atualmente existem duas maneiras comuns de gerar *deepfakes* para imagens por meio de aprendizado profundo: **com o uso de *autoencoders* e com redes neurais generativas adversárias**.

Autoencoder

Essa arquitetura de rede neurais é composta por dois blocos principais (semelhante à UNet): um *encoder* e um *decoder*.

É responsável por aprender um vetor de *features* que melhor representam as características de uma imagem.

Encoder

Utiliza o vetor de características para aprender a gerar a imagem original novamente.

Decoder

Input

Compressed feature vector

Output

- Para gerar *deepfake* com *autoencoders*, treinamos dois modelos de rede neural.
- O primeiro modelo usa imagens da pessoa que será renderizada na imagem final.
- O segundo modelo é treinado em imagens de outra pessoa, que fornece as expressões faciais ou os gestos a serem imitados.
- Após treinados esses modelos, o resultado do *encoder* da segunda rede (o vetor de características) é dado como entrada para o *decoder* do primeiro modelo, que resulta em uma imagem da primeira pessoa, mas que assumiu as expressões da segunda.

Redes neurais generativas adversárias

Nessa abordagem, duas redes neurais são treinadas juntas, e temos um gerador de imagens e um discriminador.

Aprende uma representação por meio de um vetor de características e gera imagens que enganem o discriminador.

Gerador

Seu objetivo é validar se uma imagem é real ou não.

Discriminador

Exemplo gerado

Exemplo real

Dessa forma, uma das maneiras de gerar imagens falsas é semelhante à estratégia anterior: dar ao gerador um vetor de características de uma pessoa com alguma expressão facial específica, e como *output* teremos uma imagem falsa de outra pessoa com expressões semelhantes.

A seguir, aprenda mais sobre os tipos de *deepfakes*.

Tipos de *deepfakes* em imagens

A *deepfake* é uma ferramenta importante que possibilita a edição de dados em imagens, vídeos e áudios, na intenção de alterar a

realidade dos dados originais. Dessa forma, é possível modificar o sentido contextual da informação de uma forma para outra, utilizando a edição da composição por meio da interação de mais de uma fonte de dados, ou seja, interações entre imagens com vídeo e áudio entre si.


O cinema do gênero *Jurassic Park* e *Star Wars*, a propaganda e a comunicação visual utilizam a ferramenta *deepfake*, e as interações dos dados podem ser produzidas de dois tipos, a saber:

Face swapping	↓
Como descrito anteriormente, a ideia é usar as expressões faciais de uma pessoa B para fazê-la passar-se pela pessoa A. Primeiro, detectamos a região da face da pessoa em uma imagem e, por meio do uso de uma máscara binária combinada com algoritmos de <i>machine learning</i> , trocamos a face da pessoa A por uma imagem gerada digitalmente.	
Body puppetry	↓
Movimentos, gestos, expressões faciais e todo o corpo de uma pessoa A são analisados, e então as ações são transferidas para uma pessoa B cujas imagens foram geradas artificialmente.	

Como identificar *deepfakes*

Deepfakes ainda representam um desafio para a detecção automática de vídeos e imagens falsos. Muitos modelos de detecção focam em analisar características das texturas em imagens geradas artificialmente ou ainda em *lipsync*. Contudo, esses sistemas de detecção ainda têm dificuldade em detectar imagens falsas com alta precisão.

Algumas sugestões para detecção envolvem considerar os fatores a seguir:



- Existem *features* típicas de *deepfake*, como, por exemplo, um rosto perfeitamente simétrico, óculos tortos ou com distorções nas armações, dois brincos diferentes ou algo parecido.
- Os movimentos dos lábios parecem reais? Eles correspondem ao texto falado e estão em sincronia?
- A pessoa pisca com frequência incomum?

Dessa forma, é fácil notar que, apesar de existirem alguns meios de tentar detectar se uma imagem ou vídeo é falso, nem sempre a detecção é possível na maioria das vezes. Este ainda é um tópico de pesquisa que desafia engenheiros e pesquisadores em visão computacional.



Reflita

Qual é o impacto do uso dessa tecnologia em relação a fraudes sobre dados biométricos? Como podemos contornar ou detectar ataques feitos com *deepfakes*?

Esteganografia

Esteganografia é a técnica de inserir mensagens escondidas em imagens, vídeos ou outros arquivos. Neste tópico, abordaremos o conceitos de esteganografia gerada por modelos de *machine learning* para imagens.



O objetivo principal desta técnica é que dados inseridos em imagens não sejam percebidos facilmente por terceiros; ou seja, a presença de mensagens escondidas dentro de arquivos é simplesmente desconhecida. Somente o quem tem o domínio da técnica usada deve ser capaz de recuperar a informação inserida.

Essa técnica tem sido usada recentemente em conjunto com técnicas de criptografia como auxílio para a validação de documentos e no combate a fraudes.

Em imagens, uma das técnicas clássicas é chamada de **representação pelo bit menos significativo**. A ideia se baseia na propriedade de que imagens em padrões, como o JPEG, têm redundância. Para cada componente de um canal de cor RGB, uma imagem JPEG usa a transformada de cosseno discreta (*discrete cosine transform* – DCT) para transformar blocos sucessivos de 8 x 8 pixels da imagem em 64 coeficientes de uma DCT. Assim, os bits menos significativos dos coeficientes das DCT podem ser utilizados como bits redundantes para esconder uma mensagem. Ou seja, a ideia é usar uma espécie de ruído estruturado a esses coeficientes para armazenar informação.




Mantendo o foco

A esteganografia tem inúmeras aplicações; no entanto, é relevante notar que as técnicas também têm algumas restrições. Por exemplo, o tamanho da mensagem pode impactar diretamente a qualidade da imagem gerada. Imagens com muitos artefatos podem ser facilmente detectadas, e a informação pode ser recuperada. Por isso, sempre existirá um *trade-off* entre qualidade da imagem x capacidade esteganográfica.

Recentemente, algumas técnicas foram propostas para a utilização de esteganografia usando modelos de *deep learning*, em especial modelos baseados em *autoencoders* e na UNet. O Google, em 2017, criou um dos primeiros modelos baseados em *deep learning* para esteganografia, em que foi possível inserir uma imagem colorida em tamanho real dentro de outra imagem do mesmo tamanho. Essa proposta treinou duas redes neurais profundas simultaneamente com o objetivo de criar os processos de ocultação e revelação e foi projetada para funcionar especificamente em pares. O sistema foi treinado em imagens extraídas aleatoriamente do banco de dados ImageNet.


Diferentemente de muitos métodos esteganográficos populares que codificam a mensagem secreta dentro dos bits menos significativos da imagem, essa abordagem comprime e distribui a representação da imagem secreta em todos os bits disponíveis.



StegaStamp

Um exemplo mais recente de esteganografia usando redes neurais profundas é o modelo chamado StegaStamp. O StegaStamp é um sistema cujo objetivo é gerar imagens com mensagens escondidas que sejam robustas o suficiente para serem impressas e, mesmo assim, por meio de fotografias das imagens impressas, ser possível recuperar informações escondidas.

Isso representa um desafio para a esteganografia, pois, ao mesmo tempo que geramos imagens com boa qualidade visual, é preciso ser suficientemente resistente a ruídos gerados por impressão e por capturas feitas em câmeras comuns, como as disponíveis em telefones celulares.



O objetivo do StegaStamp é esconder *hyperlinks* em imagens impressas, e estes, quando recuperados, podem acessar informações e publicidade na *web*. Essa técnica é baseada em dois modelos de redes neurais – o primeiro é uma rede neural generativa adversária, e o segundo, uma rede decodificadora de imagens.


O primeiro modelo generativo recebe como entrada uma mensagem, que, na verdade, é uma *string* de 5 até 16 caracteres. Essa mensagem é convertida para um vetor binário e, após, convertida em uma matriz binária com o mesmo tamanho da imagem original. A imagem original e a mensagem transformada são concatenadas, ou seja, a matriz binária é adicionada à imagem original como um canal a mais, além dos três canais RGB. Após, esse dado é enviado para uma rede neural baseada na UNet, cuja saída é a imagem codificada com a mensagem escondida. O segundo módulo desse modelo generativo é um discriminador que recebe a mensagem codificada e valida se ela é suficientemente parecida com a imagem original.

O segundo modelo dessa arquitetura é uma rede neural convolucional com uma camada totalmente conectada ao final. O objetivo desse módulo é receber imagens, capturadas de câmeras comuns, das fotografias impressas e descodificá-las. A saída dessa rede é um vetor binário que novamente é convertido à mensagem original.



Durante o treinamento do StegaStamp, são aplicados sucessivos métodos de simulação de ruído, a fim de imitar o processo de impressão, bem como simular variações de iluminação e ruídos relacionados a lentes de câmeras e distorções de perspectiva. Esse processo tem como objetivo trazer robustez ao modelo a fim de ser resistente a problemas encontrados no mundo real.

Um exemplo da arquitetura do StegaStamp pode ser visto nas figuras a seguir:




Técnicas como o StegaStamp trazem a oportunidade de expandir aplicações de esteganografia para imagens e documentos impressos. Um dos possíveis desdobramentos de técnicas como esta é a sua utilização para validação documentos, em que a mensagem escondida pode vir a ser um dado criptografado ou um *hash*.

Para validar a veracidade do documento, podemos utilizar um decodificador, que, a partir de uma fotografia tirada com qualquer dispositivo, seja um telefone, câmera ou *scanner*, pode recuperar essa informação e fazer o *matching* com uma base de dados. Esta é apenas uma de muitas implicações dessa tecnologia, que está em pleno desenvolvimento.

Pose estimation

A estimativa de poses é um problema desafiador em visão computacional, com muitas aplicações reais em áreas como realidade aumentada, realidade virtual, segurança e monitoramento, reconhecimento de linguagem de sinais, aplicações médicas, análise de movimento para estatísticas esportivas, entre outras. Normalmente, o problema a ser abordado envolve estimar a pose humana 2D, ou seja, os *keypoints* anatômicos ou “partes” do corpo de pessoas em imagens ou vídeos.



Hoje, os modelos de processamento de imagem mais poderosos são baseados em redes neurais convolucionais (CNNs) e *vision transformers*. Assim, praticamente todos os projetos de *pose estimation* são baseados em uma ou em uma mistura dessas duas arquiteturas.

Na detecção tradicional de objetos, as pessoas são detectadas apenas por uma *bounding box*. Diferentemente, ao realizarem a detecção de poses e *tracking* de poses, os computadores podem generalizar informações a respeito do comportamento humano.

A detecção de poses em tempo real impulsionou algumas das maiores tendências em visão computacional. Isso tem grande impacto em vários campos, como, por exemplo, na direção autônoma.


Hoje, a maioria dos acidentes de carros autônomos é causada por direção “robótica”, em que o veículo autônomo realiza uma parada permitida, mas inesperada, e um motorista humano colide com o carro autônomo. Com detecção e rastreamento de pose humana em tempo real, os computadores são capazes de entender e prever o comportamento de pedestres de forma mais eficiente.



Ainda, temos aplicações relacionadas à área da saúde. Por meio da estimativa de pose, podemos criar ferramentas auxiliares a tratamentos fisioterapêuticos. Um sistema para *pose estimation* pode analisar a movimentação de um paciente e ajudar no diagnóstico e nas recomendações feitas por profissionais da saúde.

Métodos *top-down* e *bottom-up*

Veja como esses métodos funcionam clicando na flecha a seguir:



Interativo

Interativo com o texto: Top-down: esse método estima separadamente cada posição de cada articulação do corpo de uma ou múltiplas pessoas em imagens. Posteriormente, agrupa essas posições para formar a pose de cada pessoa. Esse agrupamento normalmente é feito baseado em um grafo com pessoas associadas que descreve a pose de uma pessoa. Em uma imagem, podemos ter vários grafos representando, cada um, a pose de uma pessoa. À esquerda, vê-se quatro imagens iguais de um homem caucasiano, de jaqueta laranja, calça jeans e gorro azul, em um ambiente com bastante neve branca ao fundo. Acima, duas de top-down e, abaixo, duas de bottom-up. As de bottom-up, nesse slide, não têm qualquer marcação. No top-down, uma caixa vermelha é colocada em volta do homem, para então a imagem ao lado mostrar linhas vermelhas traçando seu corpo, com pontos em articulações. No segundo slide, vemos o texto: Bottom-up: esse método primeiramente detecta as pessoas em uma imagem de forma semelhante à detecção de objetos. Ao detectar uma pessoa, esse método define uma bounding box sobre a pessoa e estima suas articulações contidas nessa região. Normalmente, técnicas top-down demandam muito mais processamento que as bottom-up, porém são ainda mais precisas. À esquerda, vemos as mesmas quatro imagens iguais do homem. Neste slide, as de top-down não têm qualquer marcação. No bottom-up, a primeira imagem delimita os pontos de articulação do homem com bolas vermelhas, para então, na segunda imagem, linhas vermelhas traçarem seu corpo.

Estimativa de pose 2D

A estimativa de pose humana 2D é usada para estimar a posição 2D ou a localização espacial dos *keypoints* do corpo humano a partir de recursos visuais, como imagens e vídeos.

Em abordagens antigas e sem o uso de aprendizado profundo, técnicas para estimativa de pose normalmente tentavam extrair as *features* humanas de imagens e analisá-las usando algoritmos como *support vector machines*. Porém, tais abordagens eram demasiadamente imprecisas.



As abordagens modernas são baseadas em aprendizado profundo para alcançarem grandes avanços ao melhorarem significativamente o desempenho na estimativa de pose de uma pessoa ou de várias pessoas. Alguns métodos populares de estimativa de pose humana 2D incluem OpenPose, CPN, AlphaPose e HRNe.


Estimativa de pose 3D

A estimativa de pose humana 3D é usada para prever as localizações das articulações do corpo no espaço 3D. Além da pose 3D, alguns métodos também recuperam a malha 3D de pessoas de imagens ou vídeos.



Este campo tem atraído muito interesse nos últimos anos, uma vez que é usado para fornecer extensas informações da estrutura 3D relacionadas ao corpo humano. Ele pode ser empregado em várias aplicações, como indústrias de animação 3D, realidade virtual ou aumentada.

A estimativa de pose humana 3D pode ser realizada em imagens ou vídeos monoculares (câmera normal). Usando múltiplas câmeras para estimar a profundidade ou sensores adicionais (IMU ou LiDAR), a estimativa de pose 3D pode ser aplicada com técnicas de fusão de informações. Embora os conjuntos de dados humanos 2D possam ser facilmente obtidos, é demorado coletar anotações precisas de imagens de pose 3D, e a anotação manual não é prática.



Uma das técnicas mais simples e populares para estimativa de pose 3D é combinar a estimativa 2D com um modelo de regressão para informações 3D. Normalmente, nesse processo, uma rede neural para estimativa 2D pré-treinada é usada, e utilizamos sua saída com a entrada de um modelo de regressão, que tem como *ground truth* informações advindas de sensores de captura de movimento.



Fique ligado

Uma biblioteca popular que usa redes neurais para estimativa de pose humana 3D em tempo real, mesmo para casos de uso de várias pessoas, é o OpenPose.

Tracking de pose em vídeos

A estimativa de pose humana em vídeos, em situações do dia a dia e fora de ambientes controlados é complexa e requer alto poder de computação. Embora os detectores de articulações humanas mostrem bom desempenho para imagens estáticas, seu desempenho geralmente fica aquém quando os modelos são aplicados a sequências de vídeo para rastreamento de poses em tempo real. Não é incomum perceber certo *flicking* entre as detecções e ainda perder a referência de uma articulação quando nos encontramos em alguma situação em que há oclusão, ou seja, objetos ou outras pessoas se sobrepondo na imagem.

Além disso, outros desafios incluem lidar com *motion blur*, *video blur* e a incapacidade de capturar coerência temporal entre quadros de vídeo, isto é, garantir que o esqueleto gerado para uma pessoa em um quadro se mantenha com a mesma referência no seguinte. A aplicação de redes neurais recorrentes (RNN) é usada para mitigar problemas envolvendo coerência temporal.



Ainda nesse sentido, também podemos combinar redes neurais de convolução com algoritmos tradicionais para fluxo óptico, como o Kanade-Lucas-Tomasi (KLT). *Frameworks* para estimativa de pose humana em vários *frames* com coerência temporal, como DCPose, fazem uso de técnicas como estas.

Como funcionam algoritmos de CNNs para estimar a pose de uma ou mais pessoas


A estimativa de poses opera encontrando *keypoints* de uma pessoa ou objeto. Tomando uma pessoa, por exemplo, os *keypoints* seriam articulações como cotovelos, joelhos, pulsos, entre outras. Existem dois tipos de estimativa de pose: **multipose e pose única**.

Multipose	↓
Usada para detectar poses para várias pessoas.	
Pose única	↓

Usada para estimar as poses de um único indivíduo em determinada cena.

Modelos de rede neural para estimativa de pose humana treinados com o *dataset* MS COCO podem detectar 17 *keypoints* (classes) diferentes. Cada *keypoint* é anotado com três números (x, y, v), em que x e y marcam as coordenadas, e v indica se o *keypoint* está visível ou sofre de oclusão.

Vamos tomar como exemplo um modelo básico de rede neural de convolução para estimar a pose:




Em linhas gerais, normalmente esse tipo de modelo é totalmente convolucional, ou seja, sem uma camada totalmente conectada. A saída dessa rede neural, para o caso do COCO Dataset, conterá 17 mapas de calor representando cada *keypoint* encontrado na imagem.



Para estimar a posição mais precisa possível de cada *keypoint*, ainda temos o uso de técnicas como a supressão de pixel de valor no máximo. Com os possíveis candidatos a *keypoints*, basicamente o algoritmo a seguir utiliza uma técnica chamada *affinity field*, que define a ligação entre os *keypoints* a fim de conectar arestas entre eles em um grafo direcionado.

Novidade: detecção de *keypoints* de aprendizagem conjunta e associação de peças



Na próxima seção, conheça os modelos para estimativa de pose.

Modelos para estimativa de pose

O **OpenPose** é uma das abordagens *bottom-up* mais populares para estimativa de pose humana. Essa arquitetura apresenta estimativa de pose de várias pessoas em tempo real. Uma vantagem do OpenPose é que ele é uma API que oferece aos usuários a flexibilidade de selecionar a origem das imagens a serem analisadas, sejam vídeos, imagens ou *streaming* de câmeras. Ele suporta diferentes arquiteturas de *hardware*, como GPUs CUDA, GPUs OpenCL ou

dispositivos somente com CPU. Essa API pode ser usada inclusive em dispositivos embarcados em sua versão Lite.



A estimativa regional de pose multipessoal (**AlphaPose**) é um concorrente direto do OpenPose cujo método de estimativa de pose é *top-down*. Tem uma arquitetura eficiente para execução em tempo real e uma abordagem precisa para detecção combinada com a estimativa de *bouding boxes*.

O **PoseNet** é uma arquitetura de estimativa de pose construída em tensorflow.js para ser executada em dispositivos leves, como o navegador *web* ou dispositivos móveis. O PoseNet é um modelo *bottom-up* que pode ser usado para estimar uma única pose ou várias poses.

O **DensePose** é uma técnica de estimativa de pose que visa a mapear todos os pixels humanos de uma imagem RGB para a superfície 3D do corpo humano. O DensePose também pode ser usado para problemas de estimativa de pose única e múltipla. Esse modelo foi desenvolvido pelo Facebook e pode ser usado em aplicações que incluem gerar humanos digitais para filmes e animações como também pode ser aplicado em sistemas de realidade aumentada.



Fonte:<https://arxiv.org/pdf/1802.00434.pdf>

A seguir, entenda as aplicações desses modelos em *retail*.

Aplicações em *retail*

A análise do comportamento do cliente é uma questão essencial para os varejistas, permitindo otimizar o desempenho da loja, melhorar a experiência do cliente, reduzir custos operacionais e, consequentemente, obter maior lucratividade.

Umas das aplicações que envolvem visão computacional é estimar o fluxo de clientes em lojas e criar um mapa de calor a respeito de onde a maioria das pessoas concentra a sua atenção. Isso pode ajudar varejistas a distribuir melhor seus produtos ao longo da loja e estimar quais representam os de maior interesse por clientes.




Para isso, podemos usar apenas uma câmera RGB barata, como uma câmera de vigilância. Para resolver o problema de contagem de pessoas, podemos usar uma abordagem de aprendizagem supervisionada baseada em um modelo de regressão ou uma rede neural de convolução. De modo geral, algoritmos de detecção e *tracking*, como os apresentados nas seções anteriores, podem ser úteis nessa tarefa, aliados a modelos que levam em conta coerência temporal.

As informações podem ser armazenadas em um banco de dados, no qual também podemos processar estatísticas a respeito dessas detecções. Com as informações computadas, podemos usá-las posteriormente para alimentar *dashboards* ou outros sistemas de análise para estatísticas da loja.



Também podemos explorar imagens para detectar *hotspots* da loja, que posteriormente podem ser analisados visualmente. Para isso, podemos, a cada detecção de pessoas em imagens, somar os mapas de *features* de saída das redes neurais antes de serem usados para as camadas de regressão.

Esses mapas são gerados após a camada de ativação do último *layer* de convolução da rede, o que nos dá um mapa de confiança das detecções. Somando mapas em diferentes intervalos de tempo, ao final podemos calcular o mapa médio dessas detecções e gerar nossos mapas de calor a cada dia ou hora.



Redes neurais generativas adversárias

Você conhecerá dois códigos em Python explicando passo a passo cada bloco. Os códigos serão *notebooks* para gerar imagens a partir de redes generativas e estão disponíveis em [GANs](#).



Referências

Clique aqui para acessar as referências e créditos desta aula.



DU, H. *et al.* The elements of end-to-end deep face recognition: a survey of recent advances. **ACM computing surveys**, v. 54, n. 10s, p. 1-42, 2022.

FANG, H. S. *et al.* RMPE: Regional Multi-person Pose Estimation. *In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV)*. **Anais [...]**. Venice, Italy, 2017.

FERREIRA, F. A. *et al.* Scaling up cast face detection in videos at Globo. *In: XLVIII SEMINÁRIO INTEGRADO DE SOFTWARE E HARDWARE (SEMISH 2021)*. **Anais [...]**. Niterói, Rio de Janeiro, 2021.

GERSTNER, C. R.; FARID, H. Detecting real-time deep-fake videos using active illumination. *In: IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION WORKSHOPS (CVPRW)*. **Anais [...]**. New Orleans, Louisiana, 2022.

KENDALL, A.; GRIMES, M.; CIPOLLA, R. **PoseNet**: a convolutional network for real-time 6-DOF camera relocalization. 2015. Disponível em: <http://arxiv.org/abs/1505.07427>. Acesso em: 3 jan. 2023.

NOGUEIRA, V. *et al*8. RetailNet: a deep learning approach for people counting and hot spots detection in retail stores. *In: 32nd CONFERENCE ON GRAPHICS, PATTERNS AND IMAGES (SIBGRAP)*. **Anais [...]**. Rio de Janeiro, 2019.

PADNEVYCH, R. *et al.* Temporal convolutional networks for robust face liveness detection. **Pattern Recognition and Image Analysis**, p. 255-267, 2022.

PENA, R. *et al.* Globo face stream: a system for video meta-data generation in an entertainment industry setting. *In: 22nd INTERNATIONAL CONFERENCE ON ENTERPRISE INFORMATION SYSTEMS*. **Anais [...]**. Online streaming, 2020.

RAAJ, Y. *et al.* Efficient online multi-person 2D pose tracking with recurrent spatiotemporal affinity fields. *In: IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR)*. **Anais [...]**. California, USA, 2019.

SCHROFF, F.; KALENICHENKO, D.; PHILBIN, J. **FaceNet**: a unified embedding for face recognition and clustering. *In*: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2015. **Anais [...]**. Boston, 2015. p. 815-823. Disponível em: https://www.cvfoundation.org/openaccess/content_cvpr_2015/html Acesso em: 29 nov. 2022.

SURYADEVARA, N. K. Human pose estimation in the browser. *In*: SURYADEVARA, N. K. **Beginning machine learning in the browser**. Berkeley, CA: Apress, 2021. p. 65–94.

WANG, X. *et al.* **DeepFake disrupter**: the detector of deepfake is my friend. *In*: IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR). **Anais [...]**. New Orleans, Louisiana, 2022.

Banco de imagens Pexels, Pixabay, Envato, Freepik e Shutterstock.